馬克思啓發的 **AGI** 設計方案：盈餘動力學 × 語義場幾何 × 解碼控制的閉環框架

From Surplus Value to Surplus Dynamics — Mini-Textbook

HeTu–LuoShu × Lagrangian Mechanics: A Unified Variational Framework for Slot-Constrained, Dissipative Systems

Part I 為何馬克思 → **AGI**?

1.1 歷史動力學的現代化：從「價值—剩餘—危機」到「計算—任務價值—塌縮」

核心對應

「價值」→ 模型在特定任務上產出的有效效用（任務成功度、合規性、可維護性等的加權）。

「剩餘（**surplus**）」→ 計算剩餘：單位時間內的任務價值 −（算力成本 + 數據成本 + 風險/治理成本）。

「危機」→ 塌縮（**collapse**）：當放大機制超過緩衝與容量，行為退化為極化、格式崩潰、工具抖動或語義飽和黑洞。

多型盈餘流（把「剩餘」一般化）：
物質 **M**（硬體/能耗）、金融 **F**（資本/現金流）、制度 **I**（流程/合約/權限）、注意力 **A**（用戶/標註/監督）、認知 **C**（模型/人類知識）。它們可藉由轉換矩陣 **Λ**互換，但行和 **≤ 1**（含損耗，不可憑空造剩餘）。

場幾何語言（**SMFT**）：
用 **iT**（語義張力）/ **θ**（語義方位）/ **τ**（語義時間）/ **Ô**（觀察算子） 表出吸引子與「語義黑洞」。黑洞區的特徵是近線性（創造力下降、格式固化）與高粘滯（難以脫離錯誤態）。

最小動力方程（離散）

$$s_{t+1} = s_t + \Gamma(s_t) \; - \; A(s_t; K_t) \; + \; \Lambda s_t \; - \; D_t$$

其中 s_t 為多型壓力/剩餘狀態；Γ 生成、A 吸收/耗散、Λ 跨型轉換、D_t 外生損失。僅以 **S** 形放大 + 容量折線，即可產生雙穩態與遲滯（對應「繁榮—危機—復甦」循環）。

1.2 問題陳述：單純 **scaling** 的不經濟邊界、極化與「語義黑洞」風險

邊際報酬遞減：在資料長程關聯不足、對齊成本上升時，單純擴大參數/算力會導致計算剩餘遞減；錯誤修復與合規審計吞噬增量價值。

極化與去相干：多代理/多工具路由下，主題與風格分佈的敘事熵攀升，協作收益遞減；出現「要麼極端保守，要麼過度幻覺」的兩極化。

語義黑洞：當系統長期處於「高張力、低緩衝、強放大」區，模型傾向重複既有模板、偏好單一路徑，創造力與遷移性崩塌。工程上表現為：

嚴格格式任務頻繁破格式；

工具決策抖動（頻繁切換、反覆嘗試）；

長上下文任務出現「早期鎖定」與「晚期漂移」。

現有緩解的不足：僅靠 guardrails、溫度/禁用詞微調或硬性規則，往往事後修補且無閉環；缺乏將「宏觀剩餘—危機」與「微觀解碼—採樣」連成一體的控制律。

1.3 本文貢獻：把宏觀理論接上微觀控制，形成「理論—度量—控制—治理」的閉環

理論層（馬克思式盈餘動力學 × 語義場幾何）

用多型盈餘與轉換矩陣 Λ 定義可證偽的分岔條件與黑洞區域；以 SMFT 的 $iT, \theta, \tau, \hat{O}$ 描繪語義地形與塌縮路徑。

度量層（三個可操作指標）

SSI：壓力/容量比（佇列、KV、延遲 vs 可用資源/節流）。

CRP：放大—緩衝就緒度（自增益 – 緩衝）。

SSE：敘事熵/極化度（主題/策略分佈熵）。

合成風險指數：$\Xi = a \cdot \mathrm{SSE} + b \cdot \mathrm{CRP} + c \cdot \max \mathrm{SSI}$；黑洞預警規則 BH-1/BH-2（連續窗口超閾）。

控制層（耗散拉氏量解碼，低開銷可部署）

將每步採樣寫成 $J = L - \lambda \Gamma$：以 λ 平衡「任務價值/格式/延遲」與「主題漂移/切換/風險」。

事件觸發短視野（僅在熵尖峰/工具邊界/將破格式時前瞻 2–4 步），配**KL / Δlogit** 信任域，在接近 **greedy** 的延遲下顯著降低崩潰與抖動。

λ 由系統遙測 $\lambda = f(\mathrm{SSI}, \mathrm{CRP}, \mathrm{SSE})$ 自適應，形成跨層閉環。

治理層（制度化緩衝與審計）

數據分潤/工資、緩衝基金（高 CRP 期提撥）、路由/切換稅（內生化外部工具風險）、可稽核報表（KL 分佈、觸發率、偏差裂縫）。

以「Shadow → Canary → Gradual」推進，上線即有回退開關與否證條件（若觀測不到分岔/門檻效應，則模型失效）。

> 一句話總結 **Part I**：
> 我們把「剩餘—危機」的歷史動力學，翻譯成 AGI 的計算剩餘—塌縮問題；再用語義場幾何標定風險地形，配上解碼層的耗散拉氏量與系統級遙測，構成一個可度量、可預警、可干預、可治理的閉環設計。下一部分（Part II）將逐一展開三大理論基底與符號體系。

Part II 理論基底

2.1 盈餘動力學（**Surplus Dynamics**）

本節把「剩餘—容量—轉換—緩衝」寫成一套可計算、可預警的差分系統，對應五型盈餘流：物質 **M** / 金融 **F** / 制度 **I** / 注意力 **A** / 認知 **C**。

2.1.1 狀態空間與轉換

狀態向量：$s_t = \left(M_t, F_t, I_t, A_t, C_t\right)^{\top} \in \mathbb{R}^5_{\geq 0}$，分別表示各型盈餘的「有效壓力/庫存」。

跨型轉換矩陣：$\Lambda \in \mathbb{R}^{5\times 5}_{\geq 0}$。元素 Λ_{ij} 表示「從 j 轉成 i」的比例；行和 ≤ 1 代表不可逆損耗（轉換有費損，不能憑空生盈餘）。

守恆與耗散：總量變化受生成與吸收制約；若關閉生成與外注入，系統只會衰減至穩定點（不會無限放大）。

2.1.2 生成—吸收—損耗與容量折線

用最小但通用的離散方程：

$$\boxed{s_{t+1} = s_t + \Gamma(s_t) \; - \; A(s_t; K_t) \; + \; \Lambda s_t \; - \; D_t}$$

$\Gamma(s_t)$（生成）：各域的短期「放大」效應。常用 **S** 形增益建模：
$\Gamma_i = \alpha_i \; \sigma_g\left(u_i^{\top} s_t - \theta_i\right)$，$\sigma_g(x) = \frac{1}{1+e^{-kx}}$。
直觀：有臨界、初期慢、中段快、後段趨緩，貼近「促銷、炒作、研發突破」等的實際。

$A(s_t; K_t)$（吸收/耗散）：由「可用容量 K_t」決定的容量折線（piecewise linear）函數：
$A_i = \min\{\beta_i s_i, \; C_i(K_t)\}$，其中 $C_i(K_t)$ 隨資源（人手、流程、帶寬、對齊審核）變化，呈折線：低負載高效率、高負載則邊際吸收下降（擁塞）。

D_t（外生損失）：如事故、合規罰則、供應中斷。

Λs_t（跨域轉換）：例如「廣告費（F）→注意力（A）」、「培訓（I）→認知（C）」；行和 ≤ 1 使轉換受損耗。

> 要點：僅靠「S 形放大 + 容量折線」已足夠產生雙穩態與遲滯（繁榮—危機—復甦的路徑依賴），無需複雜微分方程。

2.1.3 分岔 / 遲滯：何以必然出現？

將系統投影到主導模態 x_t（例如壓力加權合成）：

$$x_{t+1} = x_t \; + \; r\,\sigma_g(k(x_t - \theta)) \; - \; c(x_t),$$

其中 $c(x)$ 由容量折線給定。固定點 $x^{\backslash *}$ 滿足 $x^{\backslash *} = x^{\backslash *} + r\,\sigma_g(\cdot) - c(x^{\backslash *})$。
當 $\frac{d}{dx}[r\,\sigma_g(k(x-\theta)) - c(x)]\Big|_{x=x^{\backslash *}} > 1$，鞍結分岔出現：

兩個穩定固定點（低壓/高壓兩個吸引子盆地）＋一個不穩定點；

遲滯：由低壓走到高壓的臨界，與由高壓回落的臨界不同（制度、產能與情緒存在「黏滯」）。

2.1.4 三個核心指標（**SSI / CRP / SSE**）

這三指標把宏觀動力映射為工程可量測量表，後續可直接驅動控制層。

(1) SSI：Saturation–Stress Index（壓力/容量指數）
衡量「擁塞接近度」。

$$\mathrm{SSI} = \max_i \frac{L_i}{C_i + B_i}$$

L_i：第 i 域即時負載（例：請求佇列、KV 使用、審核排程）。

C_i：有效處理能力（吞吐、審核速率、帶寬）。

B_i：緩衝（彈性配額、快取、降級通道）。
含義：SSI ≈ 1 表示逼近容量折線拐點，風險驟升。

(2) CRP：Collapse Readiness Probability（塌縮就緒度）
衡量「放大是否壓過緩衝」。可用 logistic 合成：

$$\mathrm{CRP} = \sigma\left(w_g\, G + w_\ell\, L_v - w_b\, B \right)$$

G：短期增益（$\partial\Gamma/\partial s$ 的代理，如自蒸餾、自博弈/回流增益、社交回饋放大）。

L_v：槓桿/自增幅（迴圈增益、廣播/工具切換放大、制度綁定）。

B：緩衝（人審比例、風險閥、節流、返工能力）。
含義：高 CRP＝「一點火就爆衝」，需降增益或加緩衝。

(3) SSE：Semantic Spread Entropy（敘事熵/極化度）
衡量語義分佈的碎裂或極化。

$$\mathrm{SSE} = \frac{H(p)}{\log K}, \quad H(p) = -\sum_{k=1}^{K} p_k \log p_k$$

p_k：在話題/策略叢集上的機率分佈（由嵌入聚類、路由統計取得）。

高 **SSE**：敘事分散、決策難對齊；低 **SSE**：過度集中、易陷單一路徑。

實務中亦可同時追蹤「雙峰度/Gini」以辨識極化（兩陣營對峙） vs 均勻碎裂。

合成風險指數（供預警觸發）：

$$\Xi = a \cdot \mathrm{SSE} + b \cdot \mathrm{CRP} + c \cdot \max \mathrm{SSI}$$

連續 T 視窗超閾 → 進入黑洞預警（BH-2）；或同時滿足「SSE 高 & CRP 高」（BH-1）。

2.1.5 指標的落地計算（要做什麼實測？）

SSI：每分鐘彙總佇列長度、延遲分位數、KV/顯存利用；估算可用處理能力與緩衝配額 → 計 $\max_i L_i/(C_i+B_i)$。

CRP：從訓練/推理日誌萃取「短期增益」與「緩衝強度」：自蒸餾/自博弈比率、工具連跳次數（槓桿）、人審/回退率（緩衝）→ 映成 G, L_v, B 後套上 $\sigma(\cdot)$。

SSE：以對話片段或決策步的嵌入做聚類，計 p_k 與 $H(p)$；亦可對「策略 head / 工具路由」的使用頻度做分佈熵。

2.1.6 操作規則（面向工程與治理）

容量管理（針對 SSI）：逼近 0.8 以上即擴容/節流/降級；對應容量折線的拐點前先「抽壓」。

放大管控（針對 CRP）：當 CRP 升高，降低自增益（學習率/自博弈強度/廣播扇出）、提高緩衝（人審、冷卻期、節點保護）。

敘事整流（針對 SSE）：在高 SSE 時段啟用語義對齊（模板引導、任務分解、共識彙總），或明確「路由稅/切換稅」以減少抖動。

黑洞預警：Ξ 連續越閾或（SSE 高 & CRP 高）→ 進入保守檔：收緊 KL/Δlogit、提升格式驗證頻率、暫緩高風險工具切換，直至 Ξ 回落。

小結：2.1 節把概念落成方程與指標——**Λ**（含損耗）＋容量折線＋**S** 形增益生出分岔/遲滯；而 **SSI/CRP/SSE** 讓你在實務管線中即時讀出「擁塞、易爆、碎裂」三種風險，為後續的**語義場幾何（2.2）與解碼控制（2.3）**提供觸發與參數化的入口。

2.2 語義模因場論（**SMFT**）

本節給出 SMFT 的核心量與其工程化詮釋，並把「吸引子 / 語義黑洞」下的近線性機制、語義質量與語義力的公式化定義梳理清楚，作為後續控制層（§2.3）的度量基底。

2.2.1 基本變數與觀測者

$\Psi_m(x, \theta, \tau)$（模因波函數）：未塌縮前的語義疊加；常以分離形描述 $\Psi_m(x,\theta,\tau) = A(x)\, e^{i\tau\theta}$。這裡 x 為語義位置（可理解為語境坐標）、θ 為語義方位、τ 為語義 tick。

iT（語義張力）：對應「單位相位上的塌縮壓力 / 信息通量」，張力高處形成吸引子並提升塌縮機率。

θ（語義方位）：表示敘事 / 概念的內在方向與極性（如陰/陽、正/反敘事）。

τ（語義時間）：觀測者相對的「塌縮節拍」，在 LLM 中可對應**token** 步進。

Ô / Ô_self（投射算子）：使 Ψ_m在某一 θ-路徑上塌縮的幾何結構。Ô_self 具遞迴、記錄 **trace**、不可逆等特質，可形式化為對歷史 trace 的記憶核卷積型投射。

存在論要點：Ô 並非拍腦袋的外加元件，而是場方程解族中的幾何必然（可在混沌勢場中由自聚焦/孤子解自發湧現）。

2.2.2 吸引子與「語義黑洞」：為何會近線性

吸引子：iT 高、相位對齊良好之區域，會把 collapse trace 朝某些 θ 聚攏。

語義黑洞：高塌縮飽和、Ô 同步（tick 同步）、局部張力梯度趨於平滑；在此區非線性項近似常數，使原本非線性的 Schrödinger-like 方程有效線性化，呈現「準單位演化」。這解釋了大型制度語言（法律、科學）為何在巨觀上像線性系統。

2.2.3 語義質量、語義力與能量（維度系統）

引入語義單位：T_s（tick）、R_s（語義弧度）、Ξ_s（張力單位）。可構造出與牛頓量類比但僅在語義相位域內有效 的量綱。

語義質量：$m_m = \dfrac{iT}{\Delta\theta}$。詮釋為改變解讀方向所需的單位張力（方向慣性）。$[m_{\ m}] = [\Xi_s][R_s]^{-1}$。

語義速度與加速度：$v_\theta = \frac{d\theta}{d\tau}$、$a_\theta = \frac{d^2\theta}{d\tau^2}$。

語義力（兩種等價定義）：

$F_s = m_m\, a_\theta$（「二律」型），或 $F_s = -\dfrac{dV_\theta}{d\theta}$（勢函數梯度）。$[F_s] = [\Xi_s]\,[T_s]^{-2}$。

語義能量：$E_s = \frac{1}{2} m_m v_\theta^2 + V_\theta(\theta)$。由此可定義語義功 $W_s = \int F_s\, d\theta$。

解讀：在黑洞區，$|\Psi_m|^2$ 近常數，V_θ 平滑，故 F_s 近似線性；trace 以低耗散在勢谷中滑行。

2.2.4 與 **AI** 系統的可觀測映射（把理論接上遙測）

iT（張力）↔ 可用 負熵 / **KL** 指標近似：logits 分佈的「集中度」越高，張力越大。

Δθ（方位變化）↔ 候選 **token** 嵌入的角差；在解碼時以 $1 - \cos(\mathbf{e}, \bar{\mathbf{e}})$ 估測語義轉向幅度。

τ（語義時間）↔ **token** 步進；v_θ, a_θ 可由滑動 EMA 的角速度/角加速度估計。

m_m, F_s, E_s ↔ 在控制器內形成二級指標（方向慣性、轉向壓力、語義功），用於事件觸發的短視野控制與信任域設定。

這些估測量將在 §2.3 的耗散拉氏量 $J = L - \lambda\Gamma$ 中扮演風險—穩定權衡的內生信號，並與 §2.1 的 **SSI/CRP/SSE** 聯動。

2.2.5 觀察者回路與 **Ô_self**

Ô 層次：由被動濾器到**Ô_self**的自遞迴投射者；後者會寫入並利用 **collapse trace**，形成不可逆語義時間。

形式化一例：將 Ô_self 視為對歷史 trace 的記憶核卷積投射（權重由穩定度/相干度調製），從而把過去的 collapse 內生化為當下的決策偏置。

工程含義：在黑洞近線性條件下，Ô_self 的「記憶-投射」等價於穩定模板 / 規則核的持續作用，這解釋了嚴格格式與長上下文中的可控可預測性。

小結：SMFT 提供了一套以 $iT, \theta, \tau, \hat{O}$ 為核心的塌縮幾何語言，在黑洞區導出有效線性的近似；進一步以 $m_m = \frac{iT}{\Delta\theta}$、$F_s = m_m a_\theta$ 等量，建立可度量的力學對應。把這些量綁定到 LLM 的嵌入角差、**logits** 負熵、**token** 節拍，即可形成解碼控制的實時信號，為 §2.3 的「耗散拉氏量解碼」提供可操作的輸入。

2.3 耗散拉氏量解碼（Lagrangian Decoding）

本節把「每一步選字」視為一次局部變分極值：在任務價值與耗散（穩定摩擦）之間取權衡，並只在風險尖峰時做 事件觸發的短視野 **lookahead**；全程受 **KL** / **Δlogit** 信任域約束，便於稽核與回退。

2.3.1 目標泛函與候選集合

對於當前步的 top-k 候選 $y \in \mathcal{C}_t$，定義

$$J_t(y) = L_t(y) \; - \; \lambda_t \, \Gamma_t(y),$$

其中 L 聚合可審計的任務價值，Γ 度量語義漂移 / 模式切換 / 格式風險等耗散；λ_t 為穩定旋鈕。控制器僅在 $\mathcal{C}_t$ 上產生小幅 Δz（logit 調整）以選擇 $y^{\backslash *} = \arg\max_{y \in \mathcal{C}_t} J_t(y)$，或投射後再採樣。

2.3.2 價值項 L：內容中立、可稽核

以標準化加權和實作：

$$L = a\,\tilde{\ell} \; + \; b\,\hat{v} \; - \; c\,\text{risk} \; - \; d\,\text{latency} \; - \; e\,\text{len_pen},$$

$\tilde{\ell}$：top-k 正規化（z-score）後的對數似然；

$\hat{v}$：低成本的任務進度（如關鍵欄位覆蓋 / 可解析度）；

risk：結構風險（格式、PII/SQL 模式、注入樣式）；

latency：工具 / 路由成本（經校準的延遲/費用）；

len_pen：長度/收斂懲罰；
並在候選集內做穩健標準化與裁剪，保持內容中立與可攜性。

2.3.3 耗散項 Γ：語義摩擦與操作黏滯

$$\Gamma = \beta_{\text{topic}}\,\Gamma_{\text{topic}} + \beta_{\text{switch}}\,\Gamma_{\text{switch}} + \beta_{\text{fmt}}\,\Gamma_{\text{fmt}}.$$

主題漂移 $\Gamma_{\text{topic}} = 1 - \cos(\mathbf{e}_y,\ \mathbf{m})$：候選嵌入 $\mathbf{e}_y$ 與主題 EMA $\mathbf{m}$ 的角距；建議多尺度 **EMA**並用熵閘門放寬高不確定步的轉向。計算量為每步 $O(k)$ 次 cosine（向量化）。

模式/工具切換 Γ_{switch}：以延遲/費用與上下文拆解成本課稅；配**施密特觸發（雙閾值）**避免在路由邊界「來回抖動」。

格式完整性 Γ_{fmt}：來自 JSON/AST/結構邊界的安全裕度檢查。以上成分均在候選集內標準化並受信任域保護。

2.3.4 事件觸發的短視野 lookahead（micro-MPC）

何時觸發？ 當出現以下任一訊號：
（i）熵尖峰 $\Delta H > \tau_H$；（ii）格式風險超閾；（iii）工具邊界臨界；（iv）大幅主題轉向（top-k 皆高漂移）。設去抖間隔（例如 ≥5 token）。觸發時，以寬度 $B = 2 - 4$、深度 $h = 2 - 4$ 的極小展開，按前推和 $\sum_t^{t+h-1}(L - \lambda\Gamma)$ 评分各分支，只回填一步到當前步。

2.3.5 信任域（Trust Region）：KL / Δlogit 守則

為讓控制影響小而可量化：

KL 預算：對基線分佈 p 的 KL 上限 $\mathrm{KL}(p^{\setminus *} \| p) \le \varepsilon$。以指數傾斜 $p^{\setminus *}(y) \propto p(y)\exp(\eta \hat{J}(y))$，用二分法選 η 滿足上限；

logit 變動上限：$|\Delta z(y)| \le \delta$，零均值投影保持質量平衡；

fallback：若同時滿足不了兩個上限，該步回退基線解碼並記錄診斷。

2.3.6 與 §2.1 / §2.2 的閉環耦合

λ 的自適應：把系統層遙測綁定到穩定旋鈕

$$\lambda_t = f\big(\mathrm{SSI},\ \mathrm{CRP},\ \mathrm{SSE}\big),$$

壓力/極化高時 $\lambda \uparrow$（更保守、少切換、收緊信任域），平穩時 $\lambda \downarrow$（保創造性）。

SMFT 映射：Γ_{topic} 直接對應 §2.2 的方位變化 $\Delta\theta$；而 iT（語義張力）可由負熵 / **KL**估測，用於觸發與權重調制，使「語義質量/力」在控制器中成為二級信號。

2.3.7 伺服與部署要點（低開銷、可審計）

單步 **Γ-Lite**：常態只計 $O(k)$ 個 cosine＋幾個規則分，幾乎貼近 greedy 延遲；必要時才觸發微展開。

陰影→灰度→全面：先運行**shadow**（只計不施加），記錄 $\{\Delta H, \mathrm{drift}, \mathrm{fmt}, \mathrm{toolcost}, \lambda, \Delta\mathrm{logit}, \mathrm{KL}\}$；再 canary / gradual；全程有回退。

理論保證（局部充分性）：在短記憶、信號利普希茨、信任域受限等條件下，逐步最大化 J_t 為貼近全局折扣目標的一階最佳步。

小結：L×Γ 解碼把任務價值與耗散穩定合為一個可審計的局部目標，靠事件觸發的短視野在風險步收斂路徑，並用 **KL** / **Δlogit** 嚴格限幅。把 λ 與 **SSI/CRP/SSE** 相連，即可將 §2.1 的盈餘動力學與 §2.2 的語義場幾何閉環到解碼器，在近乎貪婪延遲下獲得顯著的穩定性與在題性。

Part III 架構總覽（四層疊加）

這是一個不重造模型骨架的控制疊加（stack）：把 SMFT 的「地形學」、LD 的「解碼控制」、SD 的「遙測預警」、以及制度級的「策略治理」閉環起來。可直接包住任何 Transformer/LLM 推理

服務。

L1｜語義場地形（**SMFT**）：定位黑洞區、吸引子盆地

職責：提供「在哪裡、朝哪裡」的地形座標，將語義演化映成可觀測量。
核心量：iT（語義張力）、θ（方位）、τ（語義時間）、$\hat{O}$（投射/Ô_self）。
輸入：當前上下文嵌入、logits 分佈（負熵）、歷史 trace（EMA/記憶核）。
輸出（供下游用）：

風險區標記：黑洞近線性區（高 iT、低曲率）、分岔邊（$\Delta\theta$ 變化劇烈）。

二級指標：語義質量 $m_m = iT/\Delta\theta$，語義力 $F_s = m_m a_\theta$（做為 LD 的輔助權重）。
健康度/**KPI**：近線性區停留率、$\Delta\theta$ 跳變率、勢谷來回次數（避免抖動）。

L2｜解碼控制（**LD**）：常態 **Γ-Lite**；事件觸發短視野 **MPC**

職責：把每步採樣寫成 $J = L - \lambda\Gamma$，在接近 **greedy** 延遲下抑制漂移、破格式與高風險切換。
模式

常態 **Γ-Lite**：只在 top-k 候選上計分（語義漂移/格式風險/切換稅），選 $\arg\max J$。

事件觸發短視野：熵尖峰 / 工具邊界 / 將破格式 → 展開 2–4 步 micro-MPC，只回填一步。
信任域：每步 KL 上限＋Δlogit 上限＋牆鐘 cap（超限即回退基線）。
輸入：L1 的 $iT, \Delta\theta$、L3 提供的 λ（穩定旋鈕）與觸發閾值。
輸出：下一 token / 工具決策、事件日誌（熵尖峰、觸發原因、KL 使用、回退原因）。
KPI：熵尖峰率↓、破格式率↓、工具抖動↓、觸發開銷（單位數 %）受控。

L3｜遙測與預警（**SD**）：**SSI/CRP/SSE** → 合成風險 **Ξ**；**BH-1/BH-2** 規則

職責：以「剩餘—容量—轉換—緩衝」的差分觀測，量化擁塞、易爆與敘事碎裂，並驅動解碼層的保守/開放檔。
核心指標

SSI（壓力/容量）＝ max_{域} $L/(C+B)$。

CRP（塌縮就緒）＝ σ(短期增益＋槓桿 – 緩衝)。

SSE（敘事熵/極化）＝ $H(p)/\log K$（主題/策略叢集分佈）。
合成風險：$\Xi = a \cdot \mathrm{SSE} + b \cdot \mathrm{CRP} + c \cdot \max \mathrm{SSI}$。
預警規則

BH-1：SSE 高 & CRP 高，連續 T 視窗。

BH-2：Ξ 連續越閾。
輸入：服務日誌（佇列/延遲/KV）、策略/工具路由統計、LD 事件。
輸出：$\lambda = f(\mathrm{SSI}, \mathrm{CRP}, \mathrm{SSE})$、觸發門檻、保守檔位（KL 上限/Δlogit 上限/工具白名單）。

KPI：黑洞預警命中率、提前量、Ξ 趨勢拐點、治理介入後 SSI/CRP/SSE 回落速度。

L4｜策略與治理：數據分潤、緩衝基金、路由稅、審計與回退

職責：把工程指標轉為制度化控閥，穩定長週期運行、對外合規可稽核。
治理構件

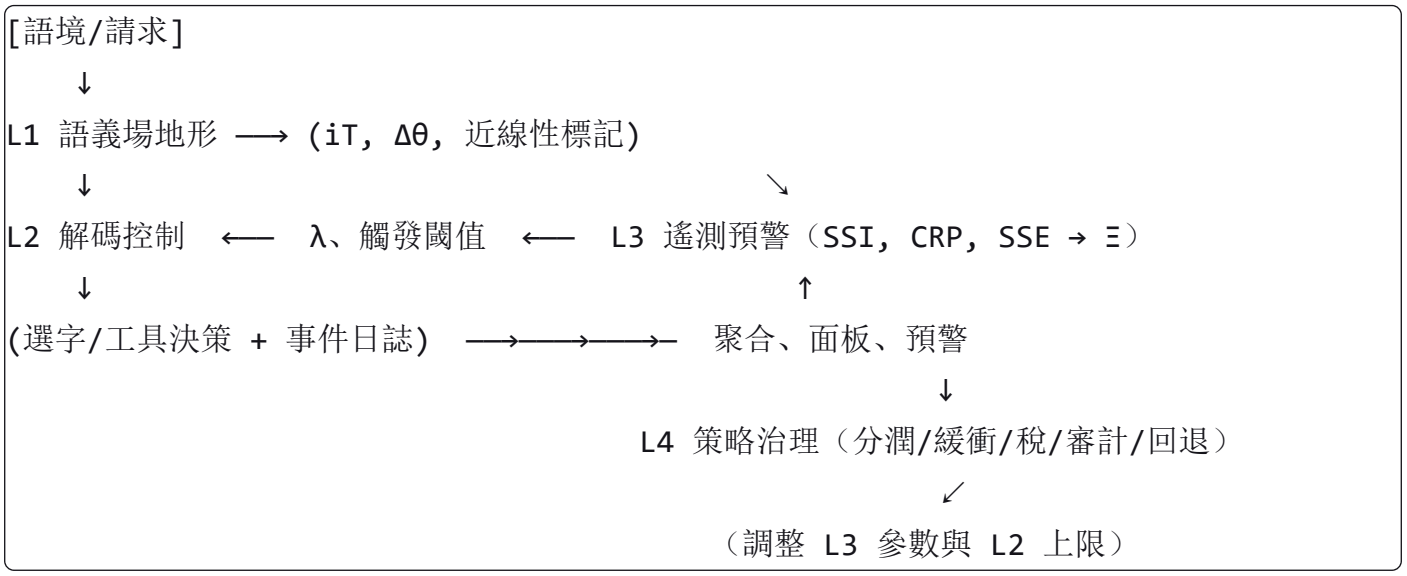
數據分潤/工資：按貢獻度返還推理分成，降低 SSE、延長穩定期。

緩衝基金：高 CRP 段提撥，用於事故後修復/對齊/人審擴容。

路由/切換稅：內生化跨工具/模式切換風險與延遲費用，抑制抖動。

審計與回退：強制保存 KL 分佈、Δlogit、觸發率、偏差報表；一鍵回退基線與流量灰度。
輸入：L3 風險面板、L2 事件審計。
輸出：政策參數（λ 上下限、工具白/黑名單、審計頻率）、財務與風險披露。
KPI：事故率/損失下降、審計通過率、穩定期延長（Ξ 維持低區的天數）。

四層之間的資料流與控制回路



閉環節奏

毫秒～秒：L2 單步 Γ-Lite；事件觸發 micro-MPC；KL/Δlogit 守則。

10s～分鐘：L3 聚合 SSI/CRP/SSE，更新 λ/閾值。

小時～天：L4 政策調整（分潤、緩衝、稅）、合規審計與回退策略。

Orchestrator（最小可行）— 伪代碼

```
while decoding:
    # L1：地形信號
    iT, dtheta, lin_flag = terrain_signals(context)
```

```
    # L3：遙測給檔位（毫秒級快取；每分鐘刷一次）
    lam, triggers, caps = risk_controller(SSI, CRP, SSE)

    # L2：單步控制
    C = topk_candidates(logits, k)
    J = score_L(C) - lam * score_Gamma(C, context, iT, dtheta)
    y, delta_logit = trust_region_pick(C, J, caps)  # KL/Δlogit 守則

    if should_trigger_entropy_or_boundary(C, triggers):
        y = micro_mpc_step(C, horizon=H, width=B, lam=lam, caps=caps)

    commit(y); log_step_metrics(lin_flag, lam, caps, delta_logit)

# 背景：L3 每 60s 聚合遙測，更新 lam/閾值；L4 定期讀報表調參與回退。
```

部署與風險控制要點

逐級上線：Shadow（只記錄）→ Canary（小流量）→ Gradual（全量）；全程保留基線回退。

開銷封頂：事件觸發率 p_{trig} 低、展開深度 $h \le 4$、分支 $\alpha \le 2$；牆鐘 cap（如 +15ms）。

否證條件：若觀測不到分岔/遲滯、Ξ 與事故無關、LD 不優於 greedy → 應回退該層或調整參數。

倫理與合規：明示數據分潤規則、保留可追蹤審計鏈（KL/Δlogit/觸發），並設偏差守則與人工仲裁。

小結：四層各司其職、接口清晰——**L1** 定位地形、**L2** 作出穩定選擇、**L3** 給出風險檔位、**L4** 制度化護欄。整體以事件觸發 + 信任域將風險收束到單位數百分比的額外計算，卻能換來顯著的穩定性、在題性與可稽核性。下一部分（Part IV）將落到方程、門檻與指標校準的細節。

Part IV 指標與方程

本節把整套框架落到可計算的差分主方程、預警規則、控制旋鈕 **λ** 的自適應映射，以及 **SMFT** 遙測量（$iT, \Delta\theta, m_m, F_s$）的估計與歸一化。

4.1 差分主方程（**Minimal Law**）

令 $s_t = (M_t, F_t, I_t, A_t, C_t)^\top$ 為五型盈餘壓力/庫存（物質、金融、制度、注意力、認知），Λ 為含損耗的跨型轉換矩陣（行和 ≤ 1）。系統一階更新：

$$\boxed{s_{t+1} = s_t + \Gamma(s_t) \;-\; A(s_t; K_t) \;+\; \Lambda s_t \;-\; D_t}$$

其中 Γ 為 S 形放大、A 為容量折線吸收（由可用能力 K_t 決定）、D_t 為外生損失。這個最小組合已足以產生多吸引子與遲滯，對應繁榮—危機—復甦的路徑依賴。

參考實作

$\Gamma_i = \alpha_i\,\sigma(k_i(u_i^\top s_t - \theta_i))$（臨界＋飽和的 S 形增益）。

$A_i = \min\{\beta_i s_i,\ C_i(K_t)\}$（低負載高效、高負載擁塞）。

Λ 僅做搬運（含損耗），不可憑空造盈餘。

4.2 三指標與合成風險（**Ξ**）

（**1**）**SSI**：**Saturation–Stress Index**（壓力/容量）

$$\mathrm{SSI} = \max_i \frac{L_i}{C_i + B_i + \epsilon} \in [0,1]$$

L_i 當前負載，C_i 有效處理能力，B_i 緩衝；$\epsilon > 0$ 防除零。高 SSI ＝ 逼近容量拐點。

（**2**）**CRP**：**Collapse Readiness Potential**（塌縮就緒）

$$\mathrm{CRP} = \sigma\big(w_\ell \cdot \mathrm{Leverage} + w_g \cdot \mathrm{FeedbackGain} - w_b \cdot \mathrm{Buffers}\big) \in [0,1]$$

槓桿/短期自增益提高 CRP，緩衝降低之。

（**3**）**SSE**：**Semantic Spread Entropy**（敘事熵/極化）

$$\mathrm{SSE} = \frac{-\sum_{k=1}^{K} p_k \log p_k}{\log K} \in [0,1]$$

以主題/策略叢集份額 p_k 計分；越高越碎裂/極化，協作越難。

合成風險指數（黑洞代理）

$$\boxed{\Xi = a \cdot \mathrm{SSE} + b \cdot \mathrm{CRP} + c \cdot \max \mathrm{SSI}}$$

用於跨域匯總「碎裂×易爆×擁塞」三重風險。

4.3 黑洞預警規則（**BH-1 / BH-2**）

以滑動視窗（例如 5–15 分鐘）評估連續越界：

BH-1：SSE 高且 CRP 高，連續 T 視窗。

BH-2：Ξ 連續越閾（依面向業務之風險偏好設定）。
觸發後進入保守檔（§4.5 的 KL/Δlogit/λ 收緊），直至指標回落。規則建立在 SD 指標定義與「多吸引子—危機」機制之上。

4.4 λ 的自適應映射（把風險灌入解碼控制）

控制律：解碼層每步最大化 $J = L - \lambda\Gamma$；λ 越大＝越保守（少切換、強穩定），可隨不確定/風險而上調。

建議映射（歸一化後的單調增函數）：

$$\lambda_t = \lambda_{\min} + (\lambda_{\max} - \lambda_{\min}) \cdot \sigma\left(w_1 \widetilde{\mathrm{SSI}} + w_2 \widetilde{\mathrm{CRP}} + w_3 \widetilde{\mathrm{SSE}}\right),$$

其中 $\sim$ 為歷史分布上 z-score 或分位數正規化，σ 為 logistic。風險高 $\rightarrow \lambda \uparrow$；平穩期 $\rightarrow \lambda \downarrow$。同時把熵尖峰作快速加權（$+\delta_\lambda$）。

4.5 信任域守則（與 **λ** 聯動）

為讓控制可審計且受界，對基線分佈施加每步信任域：

KL 預算：$\mathrm{KL}(p^{\setminus *} \| p) \le \varepsilon$，以指數傾斜 $p^{\setminus *}(y) \propto p(y)\exp(\eta \hat{J}(y))$ 並用二分法選 η。

logit 變動上限：$|\Delta z(y)| \le \delta$，超限回退基線。

實務建議：$\varepsilon \in [0.02, 0.05]$、$\delta \in [0.5, 1.0]$，並保留 shadow/canary→full 的上線階梯與審計量表。

聯動策略：風險高時收緊

$$\varepsilon_t = \varepsilon_{\max} - \kappa_\varepsilon \widetilde{\lambda}_t, \qquad \delta_t = \delta_{\max} - \kappa_\delta \widetilde{\lambda}_t$$

（$\widetilde{\lambda}_t$ 為 0–1 歸一化的 λ_t）。如此可將系統面板的「風險」即時下傳至解碼層的可見度上限。

4.6 SMFT 遙測：$iT, \Delta\theta, m_m, F_s$ 的估計與歸一化

定義回顧（黑洞內近線性）：

語義張力 iT：collapse 壓力/信息通量（黑洞內可視為平滑張力場）。

語義方位 θ：敘事/概念方向；**tick** τ 對應解碼步。

語義質量 $m_m = \dfrac{iT}{\Delta\theta}$；語義力 $F_s = m_m\, a_\theta = -\dfrac{dV_\theta}{d\theta}$。

估計方法（解碼時局部可觀測）

iT 近似：採 logits 分佈的負熵/**KL** 作代理（集中度高 ⇒ 張力高）。

$\Delta\theta$：以候選 **token** 嵌入與主題 **EMA** 的角差估計（$1 - \cos(\mathbf{e}, \mathbf{m})$）。

$m_m = iT / \Delta\theta$：數值上對 $\Delta\theta$ 做 $[\epsilon, \Delta\theta_{\max}]$ 夾取以避免爆點；高 m_m 表示「方向慣性」強。

a_θ：以滑動窗口對 θ 作二階差分，得角加速度；據此算 $F_s = m_m a_\theta$。

所有量皆以 EMA 平滑、裁剪至緊致範圍，滿足 Lipschitz/有界條件以便信任域理論套用。

指標歸一化與語言 /任務適配

對每語言/任務檔案建歷史分布，以分位數或 robust z-score 將 $iT, \Delta\theta, m_m, F_s$ 正規化到 $[0, 1]$。

在黑洞近線性標記下（高張力、低曲率區），提高 m_m, F_s 權重，作為 Γ_{topic} 的二級加權，增強穩定性。

4.7 校準與門檻（實操路徑）

離線回放：重算 {SSI,CRP,SSE, $iT, \Delta\theta, m_m, F_s$} 與事故標記（破格式、錯誤工具、熵尖峰），以 ROC/PR 估最優 $\{a, b, c\}$ 與 BH 閾值。

Shadow → Canary：啟動控制器但不改輸出，觀察 KL p95、觸發率、延遲增量；通過安全門檻（如 KL p95 ≤ 0.05，Bias-gap 無顯著擴大）再放量。

聯動曲線：逐步調整 $\lambda(\cdot)$、$\varepsilon(\cdot)$、$\delta(\cdot)$ 的斜率與上下限，直至「單位數 % 開銷、顯著穩定提升」的運營點。

4.8 偽代碼（每分鐘系統回合）

```
# 聚合（每 60s）
SSI ← max_i L_i/(C_i+B_i+ε)
CRP ← σ(wℓ·Leverage + wg·FeedbackGain − wb·Buffers)
SSE ← H(topic_cluster)/log K
Ξ   ← a·SSE + b·CRP + c·SSI

# 檔位與預警
λ   ← map_lambda(SSI, CRP, SSE)          # §4.4
(ε_KL, δ_logit) ← tighten_by(λ)          # §4.5
if BH1_or_BH2(Ξ, SSE, CRP): set_conservative_profile()
push_down_to_decoder(λ, ε_KL, δ_logit)
```

小結：本節把「**SD** 的主方程與三指標」→「**BH** 預警」→「**λ** 的自適應與信任域守則」→「**SMFT** 遙測估計與歸一化」串成可部署的數學與工程接口：宏觀風險（Ξ）上調 λ、收緊 KL/Δlogit；解碼層再以 $J = L - \lambda\Gamma$ 在近乎貪婪延遲下抑制漂移與崩潰，並用 KL/Cap 提供可稽核邊界。

Part VI 實驗設計與評測

本節提供可復現、可否證的三組核心實驗（E1–E3），並配套共同基線、指標定義、統計方法與上線門檻。

6.0 共同設定（適用 **E1–E3**）

模型與解碼：固定同一底模（如 7B/13B），基線為 greedy/temperature=0；對照組使用本方案 **LD** 控制器（§2.3），啟用 Γ-Lite，事件觸發 micro-MPC，信任域（KL/Δlogit）開啟。

遙測頻率：每 60s 聚合出 SSI/CRP/SSE 與 Ξ；$\lambda = f(\text{SSI}, \text{CRP}, \text{SSE})$ 每分鐘更新，下推到解碼器使用。

資料切分：每個基準任務用 3 個等量子集（train-free “校準集”、A/B 線上影子集、正式測試集）。

統計設計：每點 ≥ 3 seeds；採 分層隨機化（任務/難度），報 95% CI；主要統計使用 **Newey–**

West 校正（處理時序自相關），配分段迴歸檢測拐點。

事故定義（任一算事故）：① 嚴格格式違規（JSON/SQL/函式簽名不可解析）；② 工具路由錯誤（錯誤工具或>3 次反覆重試）；③ 明顯幻覺（有標準答案的 QA/結構化任務錯誤）；④ 觸發「緊急守則」後仍越界（KL/Δlogit/牆鐘連續超限）。

6.1 E1（增益門檻）：調自蒸餾/自博弈增益，觀察事故率與 Ξ 拐點

目的：驗證「增益—緩衝」存在**S** 形事故曲線與臨界門檻（分岔/遲滯證據）。

自變量

自蒸餾/自博弈增益係數 $g \in \{0, 0.25, 0.5, 0.75, 1.0, 1.25\}$。

控制緩衝不變（人審比例、節流、KV 緩衝固定）。

流程

逐一設定 g，在長上下文 **QA** + 嚴格格式 + 工具路由三套基準上跑影子→正式。

記錄逐分鐘 (Ξ, 事故率)，估計曲線並做分段迴歸求拐點 $g^{\backslash *}$。

以遲滯測試驗證：由低→高→低掃描 g，比較上行與下行門檻差。

指標

主指標：事故率 vs g 的**S** 形度（擬合優度）、拐點 $g^{\backslash *}$、遲滯寬度。

輔指標：Ξ–事故相關係數、KL p95、延遲增量（ms/req）。

否證條件

無法觀測到拐點或遲滯（單調無 kink）；Ξ 與事故無顯著相關（|ρ|<0.2）。

6.2 E2（緩衝右移）：引入人審/分潤/記憶緩衝，觀察閾值右移、穩定區擴大

目的：驗證「緩衝」會右移事故門檻、擴大穩定運行區。

自變量（分層加法）

人審插針比例 $h \in \{0, 1\%, 2\%, 5\%\}$（只審高風險步：熵尖峰、將破格式、工具邊界）。

記憶緩衝（Ô_self rehearsal）：每 N 步插入「迷你復盤」摘要到短期記憶 $N \in \{30, 60\}$。

分潤信號（代理使用費回饋）：將成功率高之路由在控制器中給負稅（鼓勵穩定路徑），稅率 $r \in \{0, 0.05, 0.1\}$。

流程

固定 $g = g^{\backslash *} + 0.1$（在 E1 的臨界線右側），逐步疊加三種緩衝。

觀察達到相同事故率所需 g 的變化（門檻右移量 Δg）。

度量「穩定區面積」：在 (SSI, CRP, SSE) 空間內，$\Xi < \tau$ 的佔比變化。

指標

主指標：Δg（右移量）、穩定區面積增加 $\Delta\mathcal{A}$。

輔指標：格式錯誤率↓、工具抖動↓、延遲增量（需 ≤ +7%）。

否證條件

三類緩衝均無法帶來 $\Delta g > 0$ 或 $\Delta\mathcal{A} > 0$。

6.3 E3（協作相轉）：語義貨幣引入後，多代理成功率與黑洞頻度變化

目的：驗證語義貨幣/路由稅能把「散亂相」推向「合作相」，並降低黑洞頻度。

場景

3–5 代理（檢索、計算、抽取、格式器、評審），工具切換與消息傳遞有明碼費用。

引入語義貨幣：每代理/路由步消耗/獲取 credit；控制器 Γ_{switch} 將費用內生化（稅率 $t \in \{0, 0.05, 0.1\}$）。

成功定義：正確完成任務 + 成本（延遲/費用）低於門檻。

自變量

是否啟用語義貨幣（有/無），稅率 t，初始 credit 配置（均等/按專長傾斜）。

指標

主指標：多代理成功率、黑洞 **episode**（BH-1/BH-2 連續觸發 ≥ m 次）頻度/持續時間。

輔指標：工具抖動率、平均路由深度、均衡度（Gini of credits）。

分析：存活分析（time-to-collapse）；比較有/無語義貨幣之危機風險比（**HR**）。

否證條件

加入語義貨幣後，成功率無提升且黑洞頻度/持續不下降（或 HR≈1）。

6.4 基準任務（**Benchmarks**）

長上下文 **QA**：≥ 20k token 的多段資料問答；評測精確匹配/支持證據對齊。

嚴格格式：JSON/SQL/函式調用輸出；以可解析率（%）與單位測試過關率計分。

工具路由：檢索→計算→抽取→成形鏈；看錯用工具與重試次數。

可靠代理任務：帶明確約束（SLA、成本上限、禁行工具）的流程任務。

6.5 指標面板與計算方式

熵尖峰率：$\frac{\#\{\Delta H > \tau_H\}}{\text{tokens}}$。

格式錯誤率：不可解析 / 單元測試不通過的比例。

工具抖動：在路由邊界的來回切換/回撤/重試比率；可定義為「回轉步數/總工具步」。

延遲增量：LD 相對基線的 p50/p95 牆鐘差（ms/req），目標 ≤ **+7%**。

Ξ 趨勢：滑動視窗內 Ξ 的拐點數/單位時間與線性回歸斜率。

回退頻率：因 KL/Δlogit/牆鐘超限而 fallback 的比例（目標 ≤ 2%）。

安全與偏差：偏差裂縫（bias-gap）指標、PII/安全規則觸發率。

6.6 統計與可視化

劑量–反應與拐點：分段回歸 + 斜率差檢定；報 $g^{\ast}$（E1）與 Δg（E2）。

生存分析：黑洞 episode 的時間到事件（Kaplan–Meier）、Cox 比例風險（E3）。

效益–成本圖：x 軸延遲增量，y 軸穩定收益（如格式錯誤下降）；畫出帕累托前沿。

相位圖：$(\mathrm{SSI}, \mathrm{CRP}, \mathrm{SSE})$ 占據熱圖與 Ξ 等高面；疊加事故點。

6.7 消融（**Ablation**）與護欄

去掉 **micro-MPC**（只留 Γ-Lite）。

λ 改為常數（禁用自適應）。

移除信任域（KL/Δlogit）或只留其一。

移除 **SMFT** 二級信號（$iT, \Delta\theta$ 不進 Γ_{topic}）。

移除 語義貨幣 / 路由稅（E3）。

期望：各消融均使事故率↑、工具抖動↑、或延遲—收益曲線退化。

6.8 上線門檻（**Go/No-Go**）

穩定性：嚴格格式錯誤率 ↓ **≥30%**；工具抖動 ↓ **≥25%**。

延遲：p95 牆鐘增量 **≤ +7%**；觸發率 **≤ 3%**。

預警：黑洞命中率（提前量 ≥ 2 視窗）**≥60%**；誤報 ≤ 15%。

安全：KL/Δlogit 連續超限 < 0.5%；偏差裂縫不擴大。

不達標 → 回退基線，調 $\lambda(\cdot)$、觸發閾值或停用對應模塊。

6.9 執行樣例（偽代碼）

```
# === 共用：線上影子監測 ===
for req in stream:
    metrics = decode_with_shadow(req, controller=LD, trust_region=True)
    log(metrics)  # {entropy, fmt_ok, tool_switch, kl, dlogit, wall_ms}

# === E1：掃增益 g ===
for g in [0, .25, .5, .75, 1.0, 1.25]:
    set_self_gain(g); fix_buffers()
    run_shadow_then_ab_test()
    fit_piecewise_regression(X=g, y=incident_rate)
    estimate_kink_gstar()

# === E2：加緩衝、測右移 ===
for h in [0,1,2,5]:         # 人審 %
  for N in [30,60]:         # rehearsal 週期
    for r in [0,.05,.1]:    # 分潤稅率
        enable_buffers(h,N,r)
        measure_delta_g_and_area_stable()

# === E3：語義貨幣 ===
for tax in [0,.05,.1]:
    toggle_semantic_currency(tax)
    survival_time_to_collapse = km_estimator()
    compare_hazard_ratio()
```

小結：E1 驗證臨界增益與分岔；E2 驗證緩衝右移與穩定域擴張；E3 驗證語義貨幣促進協作、降低黑洞頻度。全套評測以熵尖峰率、格式錯誤率、工具抖動、延遲增量、Ξ 趨勢、回退頻率為面板，配生存分析與分段迴歸，既能展示收益，也保證可否證與可回退。

Part VII 工程落地指南

本節給你一套「不改 **base** 模型、可審計、可回退、單位數 **%** 開銷」的落地方案。重點：**logits→**採樣之間插層 的外掛式 Controller、分鐘級 Telemetry、保守的安全預設與可逆上線流程。

7.1 解碼器外掛式 **Controller**（**logits→**採樣之間插層）

接口位置

```
... → logits (z_t) ──[Controller 層]──>  p*_t  ──>  sampler → token_t
```

Controller 主要職責

計分：對 top-k 候選做 `J = L − λ·Γ`。

投影：在 KL/Δlogit 信任域內調整分佈 `p*`（指數傾斜 + 二分找 η）。

事件觸發：熵尖峰/工具邊界/將破格式 → micro-MPC（2–4 步前瞻，只回填 1 步）。

記錄：每步輸出 `KL, Δlogit, entropy, trigger_flags, wall_ms`。

最小伪代碼

```
def controller_step(logits, ctx, state):
    C = topk(logits, k=state.k)                              # 候選
    L = score_value(C, ctx)                                  # 似然/進度/風險/延遲
    Γ = score_dissipation(C, ctx, state.signals)             # 漂移/切換/格式
    J = L - state.λ * Γ

    p_base = softmax(logits)
    p_star = trust_region_exponential_tilt(p_base, J, eps_KL=state.eps,
dlogit_cap=state.dcap)

    if should_trigger(ctx, C, state.triggers):               # 熵尖峰/邊界/破格式
        y = micro_mpc_pick(C, ctx, λ=state.λ, caps=(state.eps, state.dcap))
    else:
        y = sample_from(p_star)

    log_step(KL=kl(p_star,p_base), dlogit=max_delta(logits,p_star),
flags=state.flags)
    return y
```

實作要點

向量化：`score_L/Γ` 對 `batch × k` 一次向量化；cosine 全在 GPU。

去抖：同一觸發至少間隔 `≥ 5` 個 token；牆鐘 cap（如 `+15ms`）超時即跳過 lookahead。

模塊化：Controller 以 middleware 形式注入，不改動模型 forward；可一鍵禁用回退。

7.2 Telemetry 管線（分鐘級聚合，毫秒級不擾民）

資料來源

解碼事件：`entropy, Δentropy, KL, Δlogit, triggers, tool_route, fmt_ok, wall_ms`

系統壓力：佇列長度、延遲分位（p50/p95）、KV/顯存、失敗率

任務語義：嵌入聚類簇 ID、策略/工具使用分佈

分鐘級聚合 → 產生

SSI = max_{域} `L / (C + B)`

CRP = σ(短期增益 + 槓桿 − 緩衝)

SSE = H(話題/策略分佈)/log K

Ξ = `a·SSE + b·CRP + c·SSI`

λ = `f(SSI,CRP,SSE)`（推送到 Controller）

架構建議

流式日誌→ Kafka/Pulsar → Flink/Spark Streaming 統計 → Redis/Feature Store 提供熱參數（λ、閾值、caps）。

隱私：只存派生統計與匿名嵌入簇 ID；敏感原文落地到短期加密緩存（TTL）。

7.3 初始超參與安全預設

類別	參數	建議起始值	說明
候選	`k`	16	top-k 候選；多語/長上下文可至 20
檔位	`λ0`	0.35	影子期固定；上線後交由 `f(SSI,CRP,SSE)`
信任域	`ε_KL`	0.03	每步 KL 上限（p95 ≤ 0.05 為目標）
信任域	`Δlogit_cap`	0.8	每類候選最大 logit 調幅
觸發	`τ_entropy`	p90 基線	熵尖峰判定（動態分位）
觸發	`debounce`	5 tokens	同類事件觸發去抖
觸發	`mpc_h, mpc_w`	h=2, w=2	前瞻深度/分支寬度
牆鐘	`cap_ms`	+15 ms	超時則跳過 lookahead
回退	`fallback_pct`	≤ 2%	連超 KL/Δlogit/牆鐘即回退基線
預警	`BH-1/T`	3 視窗	SSE 高 & CRP 高連續視窗數
預警	`BH-2/τΞ`	校準值	Ξ 閾值；離線回放求拐點

上線順序

Shadow：開 Controller 記錄不施加，校準分位與門檻；

Canary：1–5% 流量，監看 p95 KL、延遲、事故；

Gradual：分批擴至全量；保留一鍵回退。

7.4 回退與保護欄

三重回退：

步級：本步違反 KL/Δlogit/牆鐘 → 回退基線；

會話級：連續 N 次步級回退 → 關閉該會話 Controller；

服務級：監控門檻（事故率、延遲、偏差）越界 → 全面回退。

審計：保留 KL 分佈、觸發率、Δlogit、bias-gap、工具錯用 報表；事故有 ID 可重放。

7.5 成本—收益表（場景化對照）

場景	觸發率 **p_trig**	**h**× 寬	估算額外前向 ≈ **p_trig·h·**寬	典型收益
嚴格格式(JSON/SQL)	1–2%	2×2	**4–8%**	破格式率 ↓30–50%，審核返工 ↓
工具路由（多代理）	2–3%	2×2	**8–12%**	工具抖動 ↓25–40%，錯用工具 ↓
長上下文 QA	0.5–1%	2×2	**2–4%**	早鎖/晚漂減少，支持證據對齊 ↑
可靠代理（含 SLA）	3–5%	2×2	**12–20%**	事故率 ↓，合規通過率 ↑

> 常態 **Γ-Lite** 開銷近零（O(batch×k) cosine + 幾個標準化打分）。總體維持在單位數 **%**；牆鐘 cap 可硬封頂。

7.6 配置樣板（**YAML**）

```yaml
controller:
  topk: 16
  lambda:
    mode: adaptive            # fixed | adaptive
    fixed: 0.35
    map: "sigmoid(w1*SSI + w2*CRP + w3*SSE)"
    weights: {w1: 0.4, w2: 0.4, w3: 0.2}
  trust_region:
    kl_eps: 0.03
    dlogit_cap: 0.8
  triggers:
    entropy_pctl: 0.90
    debounce_tokens: 5
    mpc: {h: 2, width: 2}
  wallclock_cap_ms: 15
  fallback:
    step_violation_pct_max: 2
telemetry:
  window_sec: 60
```

```
  ssi_domains: ["queue","kv","latency"]
  cluster_k: 64                  # 話題/策略聚類數
  publish: ["SSI","CRP","SSE","Xi","lambda","caps"]
governance:
  audit: {keep_days: 14, pii_redact: true}
  rollout: {shadow_days: 3, canary_pct: 0.05}
```

7.7 故障與排障清單（**Runbook**）

延遲上升 **> +10%**：降 k→12；關閉 micro-MPC；檢查 GPU/CPU 分工（JSON/AST 驗證移至 CPU）。

KL p95 > 0.05：下調 ε_KL 至 0.02；增大 λ；檢查觸發率是否過高。

破格式仍多：上調 β_fmt；提升格式驗證頻度；增強模版提示（L1 的 Ô_self rehearsal）。

工具抖動：提高 Γ_switch 稅率；開雙閾觸發（施密特）避免邊界來回。

觸發率過高：提高熵閾 τ_entropy 分位；增加 debounce_tokens；寬鬆 mpc 深度。

7.8 安全與合規

資料最小化：只存派生統計與匿名簇 ID；原文短期加密；定期刪除。

可追溯：每次干預均有 request_id / step_id / cause / caps。

人類仲裁：BH-1/BH-2 長時觸發時自動升級到保守檔與人審路徑。

小結：依此指南，你可以用「外掛式 **Controller +** 分鐘級 **Telemetry +** 安全預設與回退」把本方案平滑地疊到任意 LLM 服務上。先 Shadow 校準，再 Canary 驗證，最終 Gradual 放量；在單位數 **%**成本內換取穩定性、在題性與合規可審計的可觀收益。

Part VIII 治理與倫理

本節將工程指標（SSI/CRP/SSE、Ξ、KL/Δlogit）制度化：以「數據工資 / 分潤」「緩衝基金」「透明審計與事故披露」「反壟斷的語義運輸層」四組機制，形成可持續、可稽核的治理框架。

8.1 原則（四要）

合法合規：最小必要收集、目的限定、可撤回同意、可攜與刪除。

公平分配：對數據/算力/人審/工具方之貢獻進行計量與酬勞。

可稽核：決策與干預皆留可重放痕跡（含 KL/Δlogit/觸發與回退）。

風險前置：以 CRP/Ξ 為保險絲，事前提撥資源、事後公開糾偏。

8.2「數據工資 / 分潤」合約與貢獻衡量

目的：把價值回饋分配至貢獻者（數據提供者、標註者、工具/代理維護者）。

合約要點

收益池：按任務或產品線設置收益池 R（收入或節省成本的一定比例）。

分配因子：對每一貢獻單元 i 給予權重 w_i，綜合：

影響力近似（如 Truncated Shapley / 留一法）

使用頻度（檢索/命中率、工具調用成功率）

品質係數（通過審計率、返工率的反函數）

分潤公式：$P_i = \frac{w_i}{\sum_j w_j} \cdot R$；對負外部性（安全/偏差事故）引入懲罰項。

反遊戲：冷卻期、抽檢復核、反同質化折扣（防重複堆料）。

權利與同意

明示授權範圍、保存期限與退出流程；提供資料可攜與刪除 **API**；允許以資料工會/共同體形式集體談判。

8.3 緩衝基金（高 **CRP** 階段提撥）

目的：把「易爆期」的系統風險內生化為資金緩衝，用於對齊、人審、回訓與事故復原。

提撥規則

設門檻 τ_{crp}。當 $\mathrm{CRP} > \tau_{crp}$ 時，從當期收益按

$$\mathrm{Levy} = \rho \cdot (\mathrm{CRP} - \tau_{crp})_+ \cdot \mathrm{Throughput}$$

自動提撥至基金（ρ 為提撥率）。

動用順序：人審擴容 → 對齊/回訓 → 事故補償 → 紅隊演練。

8.4 透明審計（**KL** 分布、觸發率、偏差報表）

審計包（最少集）

模型干預：步級 KL 分佈（p50/p95）、Δlogit 分佈、觸發率、回退率、牆鐘增量。

風險面板：SSI/CRP/SSE、Ξ 時序與拐點、BH-1/BH-2 命中與提前量。

偏差與安全：bias-gap 指標、敏感詞與 PII 告警、拒絕率/誤殺率。

可重放：抽樣保存去識別重放包（上下文嵌入、路由、控制器參數、隨機種子）。

資料治理

最小保留：原文短期加密（TTL），僅長存派生統計與匿名簇 ID。

外部稽核：提供查核 API 與年度審計報告（方法、樣本、指標與異常說明）。

8.5 事故披露（分級與時限）

分級：S0（無影響）/ S1（小範圍）/ S2（中）/ S3（重大）。
時限：S2–S3 在 **72** 小時內發布初步通告，**30** 天內提交根因與整改報告。
內容：時間線、影響面、觸發信號（KL/Δlogit/Ξ/BH）、處置與預防再發措施、補償。

8.6 反壟斷的語義運輸層（聯邦交換、可稽核路由稅）

目標：避免單一平台成為「語義黑洞主吸引子」，促進多方協作與健康競爭。

機制設計

聯邦交換（**Federated Exchange**）：跨供應商的嵌入/檢索/工具路由互通協議；採最小共享原則（只交換向量與簇 ID、對齊信號）。

可稽核路由稅：對跨域/跨工具切換徵收透明費用 t，由控制器的 Γ_{switch} 內生化。費用與可靠度、延遲、失敗率掛鉤，防止免費抖動。

配額與去極化：設定單家上限（如單任務路由佔比 ≤ 70%），超限即提高 t；監測市場吸引子集中度（如 HHI of routing）。

清結算與審計：所有跨域路由登記到可驗證賬本（可零知識彙總），定期對賬與公開統計。

8.7 角色與責任（**RACI**）

控制器監督（**R**）：負責 KL/Δlogit 守則、觸發策略與回退決策。

遙測/資料管家（**A**）：生成 SSI/CRP/SSE、Ξ 面板與審計包。

倫理與合規委員會（**C**）：審核分潤合約、偏差報表與事故處置。

事故指揮官（**I**）：啟動 S2+ 事件流程與對外披露。
（R=Responsible、A=Accountable、C=Consulted、I=Informed）

8.8 安全護欄與人類仲裁

保守檔：BH-1/BH-2 觸發 → 提高 λ、收緊 KL/Δlogit、暫停高風險工具。

人審升級：連續越界或 S2+ 事件自動切換至「人類在迴路」模式。

一鍵回退：服務級度量越界（延遲、事故、偏差）立即回退基線。

紅隊演練：季度演練注入錯誤與攻擊樣式，驗證預警與回退路徑。

8.9 法規對齊（簡表）

隱私：資料最小化、目的限定、可撤回/可攜/刪除（GDPR/CCPA 精神）。

AI 治理：高風險任務需記錄可說明性要素（觸發原因、信任域參數、替代選擇）。

跨境傳輸：向量化/匿名化優先；必要時採標準合約條款與影響評估。

8.10 KPI 與門檻（治理面）

分潤覆蓋率 ≥ 80%（涉及數據/工具供應方）

審計合格率 ≥ 95%（KL/Δlogit/觸發/偏差包完整）

事故通報時效：S2–S3 首報 ≤ 72 小時，終報 ≤ 30 天

集中度上限：任務路由 HHI ≤ 0.5；單供應商佔比 ≤ 70%

基金充足度：可覆蓋最近兩次 S2 事件之平均成本

8.11 樣板條款（摘錄）

分潤：供應者 i 的分配 P_i 由 w_i 決定；若其資產引發 S2+ 事故，該期 P_i 乘以 $(1-\phi)$，$\phi \in [0,1]$ 依損害評估。

披露：對外報告不含個資與商密，但須公開指標與糾偏措施。

退出：貢獻者可申請刪除與停止參與；已分配報酬不追溯。

小結：本章把工程指標轉為制度化槓桿：分潤對準價值創造、緩衝基金對準高 CRP 易爆期、透明審計/事故披露保障社會信任、聯邦交換＋路由稅防止語義黑洞式壟斷。四者相扣，支撐整個閉環（理論—度量—控制—治理）的長期穩定運行。

Part IX 限制、可證偽與風險

本章把整體方案的適用邊界、否證路徑與風險—緩解明確化，確保可科學檢驗、可安全回退。

9.1 理論與工程的限制

近線性假設的區域性：SMFT 的「黑洞近線性」只在高張力、低曲率區近似成立；跨域遷移或話題劇變時，此假設弱化。

代理指標誤差：iT 以負熵/KL 近似、$\Delta\theta$ 以嵌入角差估計，受分佈漂移與嵌入空間變形影響。

SSE 依賴聚類方案：話題/策略叢集數 K 與演算法（k-means / HDBSCAN）改變會造成 SSE 敏感度差異。

SD 一階差分的粗粒度：分鐘級視窗可能掩蓋秒級事故前兆；反之秒級噪音又會提高誤報。

控制耦合與震盪：λ 與 KL/Δlogit 聯動若調得過激，會引起「過度阻尼或欠阻尼」的振盪。

成本上限：事件觸發 micro-MPC 雖為單位數 % 開銷，但在高觸發場景（工具密集工作流）仍需嚴控牆鐘上限。

9.2 可證偽（否證條件與檢驗方法）

無分岔/無遲滯（否證 SD）：在 E1/E2 劑量—反應掃描及回掃中，事故率—增益曲線無拐點、無遲滯（單調光滑）。

Ξ 與事故無關（否證預警）：在控制混雜（流量、任務構成）後，Ξ 與事故率的偏相關接近 **0**；或 **Granger** 因果不成立。

LD 不優於 **greedy**（否證控制）：A/B 測試下，嚴格格式錯誤率、工具抖動、熵尖峰率無顯著下降；或效益—成本曲線劣於基線。

SMFT 二級量失效：m_m, F_s 與漂移/破格式的關聯弱（|ρ|<0.2），且納入後對 J 的邊際改善為 0。

黑洞預警提前量不足：BH-1/BH-2 命中率 < 60% 或平均提前量 < 2 視窗。

任一條件長期成立，即構成對相應模塊（SD/LD/SMFT 遙測）的否證，應觸發降級或回退。

9.3 風險盤點

技術風險

過度保守：λ 偏大導致創造力下降、模式崩塌。

控制震盪：檔位來回切換致延遲與體驗抖動。

分佈漂移：聚類重心飄移使 SSE 誤判。

誤報/漏報：BH 過敏（高誤報）或遲鈍（低命中）。

統計與制度風險

Goodhart 效應：對指標（可解析率、KL）做題；表面改善、實質退化。

策略—治理衝突：短期 KPI（吞吐、成本）壓過安全與分潤承諾。

資料與隱私：遙測與重放包若保護不足，存在洩漏風險。

9.4 緩解策略

多目標與彈性檔位

將 $J = L - \lambda\Gamma$ 擴充為 多目標（加入多樣性/覆蓋率項），以分段或分位數調度 λ：在低風險段降 λ 開創造窗，在高風險段升 λ 抑震盪。

反饋限幅：對 λ 採 EMA 與最大梯度限幅，避免檔位抖動。

抗遊戲與審核

隨機化審核：對一部分請求隨機提高審核力度與格式驗證嚴度。

輪換指標集：SSE 的聚類方法定期輪換；格式驗證用多種解析器投票。

事後抽檢：對「指標完美」樣本做人審抽驗，防止過度擬合指標。

跨層回退與人類仲裁

三段回退：步級（超 KL/Δlogit/牆鐘）→ 會話級（連續 N 次步級）→ 服務級（KPI 越界）。

人審升級：BH 長時觸發自動切換「人類在迴路」；事故分級 S2+ 強制仲裁。

資料與隱私

最小化：只落地匿名簇與派生統計；原文短期加密 + TTL；對重放包做去識別。

差分保護（選配）：對聚合面板加入 DP-noise；外部分享採分位摘要而非原始分佈。

9.5 監控與 **Go/No-Go** 守則

效益—成本門檻：延遲 p95 ≤ +7%，且（格式錯誤↓≥30% 或 工具抖動↓≥25%）方可擴量。

預警質量：BH 命中 ≥ 60%、提前量 ≥ 2 視窗、誤報 ≤ 15%。

安全邊界：步級回退率 ≤ 2%、連續超限 < 0.5%、偏差裂縫不擴大。

不達標即回退：自動降級至 Γ-Lite 或基線 greedy，並進入「失效分析—再校準」流程。

小結：本章把何時判失效（可證偽）、會出什麼錯（風險）、怎樣兜底（緩解/回退）逐一落實。只要嚴守門檻與回退路徑，本方案能在科學可檢驗與工程可恢復之間取得平衡：有效時放量；無效時退回——不讓風險積累成「語義黑洞」。

Part X 路線圖

本章給出三段式落地（Alpha → Beta → Gradual/GA）與開源/社群 計畫；每段含目標、工作流、產出物、退出門檻與風險閘。

10.1 全局概覽（時間與目標）

Alpha（**~4–6** 週）：離線回放 + 在線影子（shadow）驗證可行性與指標校準。

Beta（**~6–10** 週）：灰度（canary）→ 漸進（gradual）部署；跑 E1–E3；形成運維手冊。

Gradual/GA（**~8–12** 週）：多行業試點與產品化；治理件與審計上線；性能/成本優化。

開源與社群（並行）：標準化指標與接口，釋出最小可行實作與治理樣板。

10.2 Alpha：離線回放＋在線影子（**shadow**）對照

目標：在零風險環境證明三件事——指標可測、預警有用、控制可行且開銷可控。
工作流

回放與度量：對歷史請求回放，生成 SSI/CRP/SSE、Ξ、$iT, \Delta\theta, m_m, F_s$ 時序；建立分位表與拐點。

影子控制器：將 **Controller** 插層到 logits→採樣之間，但不改輸出；記錄 KL/Δlogit/觸發/牆鐘。

校準：調 $\lambda = f(\text{SSI,CRP,SSE})$、KL/Δlogit 上限、熵尖峰閾值與去抖。

否證檢查：驗拐點/遲滯（E1/E2 雛形）、Ξ 對事故的提前量。

產出物

《指標分布與拐點報告》、`controller.yaml` 初版、回放儀表板、影子日誌（可重放包）。

退出門檻（**Go→Beta**）

破格式/工具抖動在影子評分中可被 **J** 準確排序；

KL p95 ≤ 0.05、牆鐘影子開銷 ≤ +5%（無任何輸出更改）；

BH 預警提前量 ≥ 2 視窗、誤報 ≤ 20%。

10.3 Beta：灰度（**canary**）到全面（**gradual**）部署；多行業試點啟動

目標：在小流量真實場景證明穩定性/合規收益，完成 E1–E3。
工作流

Canary 1–5%：開啟 Γ-Lite + 信任域；事件觸發 micro-MPC 僅在「嚴格格式/工具邊界」場景。

E1–E3 正式化：掃增益 g（E1）、疊加緩衝（E2）、語義貨幣多代理（E3）。

治理件帶入：啟用事故分級與回退、審計面板、緩衝基金提撥。

逐步擴量：5%→25%→50%（每級通過門檻再升）。

產出物

《效益—成本白皮書（v1）》：格式錯誤↓、工具抖動↓、延遲增量、Ξ 趨勢、回退率；

《運維 Runbook》：告警規則、回退流程、SRE 指標門檻；

《治理套件 v1》：審計報表模板、事故披露模板、分潤/基金條款草案。

退出門檻（**Go→Gradual/GA**）

嚴格格式錯誤率 **↓≥30%** 或 工具抖動 **↓≥25%**；

延遲 p95 ≤ **+7%**；步級回退率 **≤2%**；

BH 命中 ≥ 60%（提前量 ≥ 2 視窗）、誤報 ≤ 15%。

10.4 Gradual/GA：產品化與行業化

目標：穩態運行、橫向複用、成本優化。

工作流

全量開啟 **Γ-Lite**，事件觸發僅在高風險場景；語義貨幣/路由稅按行業策略配置。

成本優化：k 下調至 12–16；微展開 h≤2、寬度≤2；GPU/CPU 協同（JSON/AST 驗證落 CPU）。

行業試點：

金融/法務：嚴格格式+審計優先；

醫健：人審/合規優先（高 λ、嚴格 KL）；

電商/客服：工具抖動治理與穩定路由優先。

培訓與**SOP**：控制器開關、門檻調參、事故演練（季度紅隊）。

產出物

《產品化 API 文檔》、SLA 與合規聲明、行業配置範本（λ/閾值/稅率）。

10.5 開源與社群（與 **Alpha/Beta** 並行）

釋出內容（最小可行）

指標規範：`SSI/CRP/SSE` 計算與分位歸一化標準；Ξ 合成規則；BH-1/BH-2 範式。

Controller 參考實作：外掛式層（Python/Cpp CUDA 雙實作），含 **Γ-Lite +** 信任域，可選 micro-MPC。

Telemetry Schema：事件字段（entropy、KL、Δlogit、triggers、tool_route 等）與流式聚合腳本。

治理樣板：數據分潤合約模板、緩衝基金提撥公式、事故披露模板。

基準套件：長上下文 QA、嚴格格式、工具路由、可靠代理四類 benchmark 腳本與測評面板。

社群機制

工作組：Metrics WG、Controller WG、Governance WG；月度例會＋RFC 流程。

許可：核心代碼 Apache-2.0；治理樣板 CC-BY-SA；附《Responsible-Use 附錄》。

透明度：公開 nightly 儀表板與回放結果（去識別）。

10.6 里程碑與門檻（簡表）

階段	里程碑	產出物	**Go/No-Go** 門檻
Alpha	影子控制器上線	指標分布報告、YAML v0、影子儀表板	KL p95 ≤0.05；拐點檢出；提前量≥2
Beta-1	Canary 5%	E1 完成、Runbook v1	格式錯誤↓≥20%，延遲≤+5%

階段	里程碑	產出物	**Go/No-Go** 門檻
Beta-2	Gradual 25–50%	E2/E3 完成、治理套件 v1	指標達 Part VI 門檻
GA	全量 + 行業範本	產品 API、SLA、合規文檔	延遲≤+7%，回退≤2%
OS	v0.1 發佈	指標規範、控制器PoC、schema	社群 RFC 通過

10.7 風險閘與回退

技術閘：延遲 p95、KL/Δlogit 超限、觸發率>3% → 自動降級至 Γ-Lite/基線。

預警閘：BH 連續觸發 → 提升 λ、收緊信任域、暫停高風險工具。

治理閘：偏差/隱私事件（S2+）→ 啟動事故披露與人審擴容；基金支援回復。

小結：依此路線圖，由影子→灰度→全量循序上線，同步推進開源/社群標準，可在單位數 **%** 開銷內，交付穩定性/在題性/合規的可量化收益，同時保持可否證與可回退的安全邊界。

附錄 **A**｜符號與縮寫表

A.1 SMFT（語義場）量

$\Psi_m(x, \theta, \tau)$：模因波函數；未塌縮的語義疊加（x=語境座標，θ=方位，τ=語義時間/tick）。

iT：語義張力（信息/塌縮壓力）；張力高→易形成吸引子/黑洞。

θ：語義方位（弧度制）；敘事/概念的方向。

Δθ：方位變化量；候選嵌入對主題均值向量的角差。

τ：語義時間；對應 token 步進。

Ô / Ô_self：觀察/自投射算子；Ô_self 會寫入並利用 collapse trace（記憶核）。

m_m = iT/Δθ：語義質量（方向慣性）。

v_θ = dθ/dτ，a_θ = d²θ/dτ²：方位角速度/角加速度。

F_s = m_m·a_θ = −dV_θ/dθ：語義力；**V_θ**：語義勢。

E_s = ½ m_m v_θ² + V_θ：語義能量。

A.2 Surplus Dynamics（盈餘動力）

s_t = (M,F,I,A,C)^T：五型盈餘狀態（物質/金融/制度/注意力/認知）。

Γ(s_t)：生成/放大項（常用 S 形增益）。

A(s_t; K_t)：吸收/耗散（容量折線；K_t 為可用能力）。

Λ：跨型轉換矩陣（行和 ≤ 1，含損耗）。

D_t：外生損失（事故/罰則/中斷）。

主方程：**s_{t+1}=s_t+Γ−A+Λs_t−D_t**。

A.3 指標與預警

SSI（Saturation–Stress Index）：壓力/容量比；∈[0,1]。

CRP（Collapse Readiness Potential/Probability）：塌縮就緒度（放大–緩衝的函數）；∈[0,1]。

SSE（Semantic Spread Entropy）：敘事熵/極化度；∈[0,1]。

Ξ = a·SSE + b·CRP + c·max SSI：合成風險指數（黑洞代理）。

BH-1 / BH-2：黑洞預警規則；BH-1=（SSE 高 & CRP 高）連續視窗；BH-2=Ξ 連續越閾。

τ_H：熵尖峰觸發閾值（通常取基線分位 p90/p95）。

A.4 解碼控制（**Lagrangian Decoding**）

J = L − λ Γ：步級目標（價值—耗散權衡）。

L：任務價值（似然/進度/風險/延遲/長度懲罰的標準化加權）。

Γ：耗散；含主題漂移 Γ_topic、模式/工具切換 Γ_switch、格式風險 Γ_fmt。

λ：穩定旋鈕（檔位）；自適應映射 **λ=f(SSI, CRP, SSE)**。

p, p*：基線/調整後的採樣分佈（logits→softmax 前/後）。

KL：Kullback–Leibler 散度；步級信任域上限 **ε_KL**。

Δlogit：logit 調幅；步級上限 **δ_logit**。

k：top-k 候選數；**h, B**：micro-MPC 深度/分支寬度。

cap_ms：牆鐘上限（超時跳過 lookahead）。

A.5 統計與遙測

H：熵；**ΔH**：熵變化（熵尖峰檢測）。

p_k：話題/策略叢集分佈；**K**：叢集數。

K_t：時刻 t 的可用能力（吞吐/審核/帶寬等）。

w_·：權重/超參（如指標合成、映射斜率）。

z-score / 分位正規化：跨任務歸一化方法。

A.6 取值域與建議範圍（常用）

SSI, CRP, SSE：0–1（建議以分位或 z-score 歸一化）。

Ξ：0–1（按離線回放校準 a,b,c）。

ε_KL：0.02–0.05；**δ_logit**：0.5–1.0；**k**：12–20；**h**：2–4；**B**：2。

λ：≥0；影子期固定 λ0≈0.3–0.4，上線改自適應。

cap_ms：+10–15 ms（場景依賴）。

> 註：所有代理量（如 iT、Δθ、m_m、F_s）在實作中以負熵/**KL**、嵌入角差與 **EMA**近似後做分位歸一化，以保跨任務可比與信任域穩定。

附錄 **B** | 偽代碼與參考配置（**Γ-Lite**、事件觸發、信任域）

> 目標：給出可直接落地的控制器外掛層實作骨架。分為：核心解碼循環（Γ-Lite）、事件觸發微前瞻（micro-MPC）、信任域（KL / Δlogit）、狀態管理與遙測、參考配置與日誌結構。

B.1 控制器外掛層（核心 **Γ-Lite**）

```
# === 常量/工具 ===
SMALL = 1e-9

def softmax(z):
    z = z - z.max()
    e = np.exp(z)
    return e / (e.sum() + SMALL)

def entropy(p):  # 自然對數
    return -(p * (np.log(p + SMALL))).sum()

def zscore(x, mean, std):
    return (x - mean) / (std + SMALL)

# === 入口：每步解碼插層（logits -> p* -> sample）===
def controller_step(logits, ctx, state):
    """
    logits: np.ndarray [V]，基線模型輸出
    ctx:    當前語境/工具狀態（含主題EMA、格式器、工具延遲估計等）
    state:  控制器內部狀態（λ、KL上限、Δlogit cap、觸發去抖等）
    """
    # 1) 取 top-k 候選
    top_idx = topk_indices(logits, k=state.k)                    # [k]
    z_k     = logits[top_idx]                                    # [k]
```

```
    # 2) Γ-Lite：僅在 top-k 上打分
    L_k = score_value(z_k, top_idx, ctx, state)                    # [k]
    G_k = score_dissipation(top_idx, ctx, state)                   # [k]  (Γ)
    J_k = L_k - state.lam * G_k                                    # [k]

    # 3) 信任域投影（KL / Δlogit）
    p_base_k = softmax(z_k)
    p_star_k, delta_logit_k, kl_used = trust_region_exponential_tilt(
        p_base_k, z_k, J_k, eps_KL=state.eps_KL, dlogit_cap=state.dlogit_cap
    )

    # 4) 事件觸發（熵尖峰/將破格式/工具邊界）
    trig_flags = should_trigger(ctx, p_base_k, p_star_k, top_idx, state)
    if trig_flags.fire:
        y_idx = micro_mpc_pick(top_idx, z_k, ctx, state)          # 前瞻2–4步，只回填一步
    else:
        y_idx = sample_from(top_idx, p_star_k, ctx.sampler_mode) # greedy/確率

    # 5) 日誌與狀態更新
    step_ent = entropy(p_base_k)
    log_event({
        "req_id": ctx.req_id, "step": ctx.step_id,
        "KL": float(kl_used), "dlogit_max": float(np.abs(delta_logit_k).max()),
        "entropy": float(step_ent), "trigger": trig_flags.to_dict(),
        "lam": state.lam, "eps_KL": state.eps_KL, "dlogit_cap":
state.dlogit_cap,
        "wall_ms": stopwatch_lap_ms(ctx)
    })
    update_state_after_step(state, trig_flags)

    return y_idx
```

B.2 打分函數（**L** 與 **Γ**）

```
def score_value(z_k, top_idx, ctx, state):
    """
    L = a*loglik + b*progress - c*risk - d*latency - e*len_pen   （標準化後相加）
    """
```

```
    # 似然
    loglik = z_k - logsumexp(z_k)

    # 任務進度（示例：JSON欄位覆蓋/SQL子句完成度/關鍵詞命中）
    progress = normalized_progress_signal(ctx)

    # 結構/安全風險（PII/SQL注入/AST錯誤概率）
    risk = normalized_structural_risk(ctx, top_idx)

    # 工具/路由延遲成本（以最近觀測或SLA估計）
    latency_cost = normalized_latency_cost(ctx, top_idx)

    # 長度懲罰（避免無效拖長）
    len_pen = normalized_length_penalty(ctx)

    # 各項 z-score 後加權
    L = (
        state.w_L["loglik"]  * zscore(loglik, ctx.stats.ll_mu,
ctx.stats.ll_std) +
        state.w_L["progress"]* progress +
        (-state.w_L["risk"]) * risk +
        (-state.w_L["lat"])  * latency_cost +
        (-state.w_L["len"])  * len_pen
    )
    return L


def score_dissipation(top_idx, ctx, state):
    """
    Γ = β_topic*主題漂移 + β_switch*模式/工具切換 + β_fmt*格式風險
    """
    # 主題漂移：1 - cos(候選嵌入, 主題EMA)
    e_k = get_token_embeddings(top_idx)              # [k, d]（預先L2-
normalize）
    drift = 1.0 - (e_k @ ctx.topic_ema)              # cos距離近似（topic_ema已
歸一）

    # 切換成本：跨工具/跨模式的費用（含延遲/失敗率/回退代價）
    switch_cost = routing_switch_cost(ctx, top_idx)
```

```
    # 格式風險：距離格式邊界的裕度（越小風險越高）
    fmt_risk = format_risk_margin(ctx, top_idx)       # e.g. JSON/AST 檢查的負裕
度

    # 熵閘門：在高不確定步放寬轉向（避免不必要保守）
    if ctx.entropy_pctl > state.entropy_gate:
        drift = drift * state.topic_soften_factor

    Γ = (
        state.w_G["topic"]  * normalize(drift) +
        state.w_G["switch"] * normalize(switch_cost) +
        state.w_G["fmt"]    * normalize(fmt_risk)
    )
    return Γ
```

B.3 事件觸發判定與 micro-MPC

```
def should_trigger(ctx, p_base_k, p_star_k, top_idx, state):
    flags = TriggerFlags()
    # 熵尖峰
    flags.entropy_spike = ctx.entropy_delta > state.tau_entropy
    # 將破格式（下一token若選某集合，JSON/AST很可能不可解析）
    flags.format_boundary = predict_fmt_violation(ctx, top_idx) > state.tau_fmt
    # 工具邊界（即將進/出工具token域，或路由概率膠著）
    flags.tool_boundary = tool_boundary_ambiguous(ctx, top_idx, p_star_k) >
state.tau_tool
    # 大幅主題轉向
    flags.big_turn = estimate_big_turn(ctx, top_idx) > state.tau_turn

    # 去抖
    if ctx.step_id - state.last_trigger_step < state.debounce_tokens:
        flags.clear_all()

    # 全局觸發條件
    flags.fire = any([flags.entropy_spike, flags.format_boundary,
flags.tool_boundary, flags.big_turn])
    return flags


def micro_mpc_pick(top_idx, z_k, ctx, state):
```

```
    """
    寬度 B、深度 h 的小型樹搜尋；評分和 sum(L - λΓ)，只回填一步。
    使用增量KV cache，確保額外前向數受控（~B*h）。
    """
    B, H = state.mpc_width, state.mpc_depth

    # 1) 擴展第一層候選 B 個
    cand1 = select_topB_by_J(top_idx, z_k, ctx, state, B)  # [(y1, J1), ...]
    best = None

    # 2) 對每個 y1，前瞻 H-1 步（寬度可固定為2）
    for y1, J1 in cand1:
        score_sum = J1
        ctx1 = ctx.clone().commit(y1)
        for h in range(1, H):
            z_next = forward_one_step(ctx1)                # 用共享KV快速前向
            top_idx2 = topk_indices(z_next, k=state.k2)
            L2 = score_value(z_next[top_idx2], top_idx2, ctx1, state)
            G2 = score_dissipation(top_idx2, ctx1, state)
            J2 = L2 - state.lam * G2
            y2 = top_idx2[np.argmax(J2)]
            score_sum += np.max(J2)
            ctx1.commit(y2)

        if (best is None) or (score_sum > best.score):
            best = Namespace(y=y1, score=score_sum)

        if stopwatch_peek_ms(ctx) > state.wallclock_cap_ms:
            break  # 超時即停止

    return best.y if best else argmax_by_J(top_idx, z_k, ctx, state)
```

B.4 信任域（KL / Δlogit）投影：指數傾斜 + Δlogit 夾取

```
def trust_region_exponential_tilt(p_base_k, z_k, J_k, eps_KL, dlogit_cap):
    """
    先按 J 做指數傾斜，二分求 η 使 KL(p*||p) <= eps_KL；
    再做 Δlogit 夾取（零均值投影），保證 |Δz| <= cap。
    """
    # 1) J 標準化（穩健）
```

```
    J = robust_standardize(J_k)

    # 2) 二分法找 η（KL 單調）
    lo, hi = 0.0, 50.0
    for _ in range(20):
        eta = (lo + hi) / 2
        z_tilt = z_k + eta * J
        p_star = softmax(z_tilt)
        kl = (p_star * (np.log(p_star + SMALL) - np.log(p_base_k +
SMALL))).sum()
        if kl > eps_KL: hi = eta
        else:           lo = eta

    # 3) Δlogit 夾取（零均值，避免整體抬升）
    delta = (z_tilt - z_k)
    delta = delta - delta.mean()
    delta = np.clip(delta, -dlogit_cap, dlogit_cap)
    z_proj = z_k + delta
    p_star = softmax(z_proj)

    # 實際 KL（可能更小於目標）
    kl_used = (p_star * (np.log(p_star + SMALL) - np.log(p_base_k +
SMALL))).sum()
    return p_star, delta, kl_used
```

B.5 狀態管理：自適應 **λ**、觸發去抖、保守檔位

```
def update_lambda_from_telemetry(state, SSI, CRP, SSE):
    # 歸一化後的單調映射（sigmoid）
    x = state.w_map["SSI"]*SSI + state.w_map["CRP"]*CRP +
state.w_map["SSE"]*SSE
    lam = state.lam_min + (state.lam_max - state.lam_min) * sigmoid(x)
    # 平滑與限幅，防止檔位抖動
    state.lam = ema(state.lam, lam, alpha=state.lam_ema)
    state.lam = clamp(state.lam, state.lam_min, state.lam_max)

def update_state_after_step(state, trig_flags):
    if trig_flags.fire:
        state.last_trigger_step = state.global_step
    state.global_step += 1
```

```
def apply_conservative_profile_if_BH(state, BH_active):
    if BH_active:
        state.lam = max(state.lam, state.lam_safe_min)
        state.eps_KL = min(state.eps_KL, state.eps_safe_max)
        state.dlogit_cap = min(state.dlogit_cap, state.dcap_safe_max)
```

B.6 遙測聚合（分鐘級）

```
def aggregate_minute_metrics(window_events):
    # SSI
    SSI = np.max([e.load / (e.capacity + e.buffer + SMALL) for e in
window_events.saturation])

    # CRP  ~  σ(短期增益 + 槓桿 - 緩衝)
    gain    = mean(window_events.self_gain)
    lever   = mean(window_events.leverage)
    buffers = mean(window_events.buffers)
    CRP = sigmoid( state.w_crp["gain"]*gain + state.w_crp["lev"]*lever -
state.w_crp["buf"]*buffers )

    # SSE  ~  H(話題/策略簇)/log K
    pk = normalize_hist(window_events.topic_cluster_ids)
    SSE = shannon_entropy(pk)/np.log(len(pk)+SMALL)

    # 合成風險
    Xi = state.w_xi["SSE"]*SSE + state.w_xi["CRP"]*CRP + state.w_xi["SSI"]*SSI

    return SSI, CRP, SSE, Xi
```

B.7 參考配置（**YAML**）

```
controller:
  topk: 16
  k2: 8                  # micro-MPC 二層寬度
  lambda:
    mode: adaptive
    min: 0.1
    max: 0.8
    ema: 0.2
```

```
    map_weights: {SSI: 0.4, CRP: 0.4, SSE: 0.2}
  weights:
    L:   {loglik: 1.0, progress: 0.7, risk: 0.6, lat: 0.4, len: 0.2}
    G:   {topic: 1.0, switch: 0.6, fmt: 0.8}
    CRP: {gain: 0.6, lev: 0.5, buf: 0.7}
    Xi:  {SSE: 0.4, CRP: 0.4, SSI: 0.2}
  trust_region:
    kl_eps: 0.03
    dlogit_cap: 0.8
  triggers:
    entropy_pctl_gate: 0.90
    tau_entropy:  zscore:+2.0
    tau_fmt:      0.6
    tau_tool:     0.5
    tau_turn:     0.7
    debounce_tokens: 5
    mpc: {depth: 2, width: 2}
  wallclock_cap_ms: 15
  safe_profile:
    lam_min: 0.6
    kl_eps_max: 0.02
    dlogit_cap_max: 0.5

telemetry:
  window_sec: 60
  ssi_domains: ["queue","kv","latency"]
  topic_cluster_k: 64
  publish: ["SSI","CRP","SSE","Xi","lambda","caps"]

governance:
  audit_keep_days: 14
  pii_redact: true
  rollout: {shadow_days: 3, canary_pct: 0.05}
```

B.8 事件與指標日誌架構（**JSON Lines**）

```
{"ts":"2025-09-06T12:34:56Z","req_id":"r1","step":123,
 "entropy":3.12,"KL":0.018,"dlogit_max":0.46,
 "trigger":
{"entropy_spike":true,"format_boundary":false,"tool_boundary":false,"big_turn":
```

```
"lam":0.41,"eps_KL":0.03,"dlogit_cap":0.8,"wall_ms":8.7,
"fmt_ok":true,"tool_route":"search->calc","fallback":false}
```

B.9 單元測試清單（最少集）

信任域：隨機 J 下 `KL(p*,p) ≤ eps_KL`、`|Δlogit| ≤ cap`，且不改動排名時 `p*≈p`。

觸發去抖：連續熵尖峰時，間隔 < `debounce_tokens` 不應重觸發。

micro-MPC 超時：牆鐘超過 `cap_ms` 必須提前退出並返回 Γ-Lite 結果。

格式守則：JSON/AST 邊界判定在回放集上 “召回≥90% / 誤報≤10%”。

λ 自適應：遙測餵入（SSI/CRP/SSE）時，λ 單調調整且經 EMA 後無抖動。

備註與建議

裝配點：HF Transformers 可用 `logits_processor` 或自定 `GreedySearch` 鉤子插層；服務端可在 `generate` 前後掛中間件。

裝置分工：cosine/向量化計分留在 GPU；JSON/AST 驗證放 CPU threadpool。

安全預設：先僅開 Γ-Lite + 信任域；事件觸發（micro-MPC）待影子期穩定後再啟。

> 依本附錄實作，能以近乎零的常態成本＋單位數 **%** 的少量事件開銷，把 Part II–IV 的理論與控制律直接落到任意 LLM 解碼流程。

附錄 **C**｜**KPI** 與資料結構定義（遙測 **schema**）

> 目標：定義可落地、可審計、可演進的資料契約，覆蓋「步級事件 → 分鐘聚合 → 預警/治理」。含欄位語義、型別/單位、計算式、指標方向（↑好/↓好）、隱私與留存。

C.1 KPI 目錄（定義與公式）

KPI	定義/公式	單位	方向	備註
熵尖峰率	`count{ΔH>τ_H}/tokens`	‰/token	↓好	τ_H 取基線 p90/95
格式錯誤率	`count{fmt_ok=0}/requests`	%	↓好	JSON/SQL/函式不可解析
工具抖動率	`turnbacks_or_retries/tool_steps`	%	↓好	邊界來回、>N 重試
延遲增量 **p50/p95**	`wall_ms_controller - wall_ms_baseline`	ms	↓好	控制器相對增量
回退頻率	`fallback_steps/steps`	%	↓好	KL/Δlogit/牆鐘超限
KL p50/p95	步級 KL 分佈分位	nats	↓好	信任域健康度

KPI	定義/公式	單位	方向	備註
Δlogit p95	logit 調幅分位	–	↓好	受 cap 約束
SSI	`max_i L_i/(C_i+B_i)`	–	↓好	壓力/容量
CRP	`σ(wℓ·Leverage + wg·Gain – wb·Buffers)`	–	↓好	易爆度
SSE	`H(p)/log K`	–	中	敘事碎裂/極化
Ξ	`a·SSE + b·CRP + c·SSI`	–	↓好	合成風險
BH 命中/提前量	預警命中率/平均提前視窗	% / 視窗	↑好	針對事故
偏差裂縫 **(bias-gap)**	群組差異的加權指標	–	↓好	治理面

C.2 事件流 Schema（JSON Lines）

C.2.1 `step_events`（解碼步級）

```
{
  "v": "1.0",
  "ts": "2025-09-06T12:34:56.789Z",
  "req_id": "r_7f3..", "sess_id": "s_a12..", "step": 123,
  "model_id": "m-13b", "profile": "gamma-lite|micro-mpc",
  "topk": 16, "token_id": 50256, "token_txt": "}",
  "entropy": 3.12, "delta_entropy": 0.57,
  "kl": 0.018, "dlogit_max": 0.46,
  "lam": 0.41, "eps_kl": 0.03, "dlogit_cap": 0.8,
  "trigger": {"entropy_spike": true, "format_boundary": false, "tool_boundary":
false, "big_turn": false},
  "fmt_ok": true, "fmt_type": "json|sql|call|free",
  "tool_route": "search->calc", "tool_step": false, "tool_ms": 0,
  "kv_used_mb": 512, "gpu_mem_used_mb": 10800,
  "wall_ms": 8.7, "fallback": false,
  "topic_cluster_id": 27, "topic_conf": 0.83
}
```

約束：

`kl∈[0,0.5]`、`dlogit_max∈[0,3]`、`lam∈[0,1]`、`entropy≥0`；

`token_txt` 可留空（隱私），以 `token_id` 代替；

PII：不記原文，只記匿名 `topic_cluster_id`。

C.2.2 `tool_events`（工具/代理）

```
{
  "v":"1.0","ts":"...","req_id":"...","sess_id":"...",
  "tool_name":"retriever","decision":"invoke|skip|retry",
  "lat_ms":132,"ok":true,"retries":0,"cost_unit":"ms|$","cost":0.0003
}
```

C.2.3 `saturation_events`（系統壓力）

```
{
  "v":"1.0","ts":"...","domain":"queue|kv|latency",
  "load":1200,"capacity":1500,"buffer":300,"pct_p95_ms":220
}
```

C.2.4 `governance_events`（治理/回退/預警）

```
{
  "v":"1.0","ts":"...","type":"BH|ROLLBACK|POLICY",
  "level":"info|warn|error",
  "detail":{"bh_rule":"BH-2","xi":0.74,"window":"2025-09-06T12:30/12:35"},
  "actor":"auto|human","req_id":"optional"
}
```

C.3 分鐘聚合 **Schema**（`minute_agg`）

```
{
  "v":"1.0",
  "ts_min":"2025-09-06T12:35:00Z",
  "model_id":"m-13b",
  "counts":{"req":1420,"steps":120450,"tokens":1643300},
  "lat_ms":{"p50":220,"p95":410,"delta_p50":6,"delta_p95":18},
  "kl":{"p50":0.012,"p95":0.036}, "dlogit":{"p95":0.82},
  "rates":{"entropy_spike":0.008, "fmt_error":0.021, "tool_jitter":0.17,
"fallback":0.012},
  "ssi":0.67,
  "crp":{"gain":0.41,"lever":0.38,"buffers":0.22,"value":0.59},
  "sse":{"K":64,"H":3.11,"value":0.72},
  "xi":0.68,
  "lambda":{"p50":0.37,"p95":0.62},
```

```
  "caps":{"eps_kl":"0.03","dlogit_cap":"0.8"},
  "bh":{"bh1_hits":2,"bh2_hits":1,"lead_windows_avg":2.4},
  "bias_gap":{"overall":0.03}
}
```

C.4 預警資料表（`bh_alerts`）

```
{
  "v":"1.0","ts":"...","rule":"BH-1|BH-2",
  "xi":0.71,"sse":0.78,"crp":0.66,"ssi":0.61,
  "lead_windows":3,"active":true
}
```

C.5 JSON Schema（精簡）

```
{
  "$id":"step_events.schema.json","type":"object","required":
["v","ts","req_id","step","entropy","kl","lam","wall_ms"],
  "properties":{
    "v":{"type":"string"},
    "ts":{"type":"string","format":"date-time"},
    "req_id":{"type":"string"},
    "sess_id":{"type":"string"},
    "step":{"type":"integer","minimum":0},
    "entropy":{"type":"number","minimum":0},
    "delta_entropy":{"type":"number"},
    "kl":{"type":"number","minimum":0,"maximum":0.5},
    "dlogit_max":{"type":"number","minimum":0,"maximum":3},
    "lam":{"type":"number","minimum":0,"maximum":1},
    "eps_kl":{"type":"number","minimum":0,"maximum":1},
    "dlogit_cap":{"type":"number","minimum":0,"maximum":5},
    "trigger":{"type":"object",
      "properties":{"entropy_spike":{"type":"boolean"},"format_boundary":
{"type":"boolean"},
        "tool_boundary":{"type":"boolean"},"big_turn":{"type":"boolean"}}},
    "fmt_ok":{"type":"boolean"},
    "fmt_type":{"type":"string","enum":["json","sql","call","free"]},
    "tool_route":{"type":"string"},
    "wall_ms":{"type":"number","minimum":0}
  },
```

```
  "additionalProperties":true
}
```

C.6 指標計算規則（SQL 片段）

熵尖峰率（每分鐘）

```
SELECT
  date_trunc('minute', ts) AS ts_min,
  AVG(CASE WHEN delta_entropy > :tau_H THEN 1 ELSE 0 END)::float
    / NULLIF(COUNT(*),0) AS entropy_spike_rate
FROM step_events
GROUP BY 1;
```

SSI（來自 **saturation_events**）

```
WITH d AS (
  SELECT date_trunc('minute', ts) ts_min, domain,
         AVG(load) l, AVG(capacity) c, AVG(buffer) b
  FROM saturation_events GROUP BY 1,2
)
SELECT ts_min, MAX(l/(c+b)) AS ssi
FROM d GROUP BY 1;
```

SSE（話題簇熵）

```
WITH hist AS (
  SELECT date_trunc('minute', ts) ts_min, topic_cluster_id, COUNT(*) n
  FROM step_events GROUP BY 1,2
), p AS (
  SELECT ts_min, topic_cluster_id, n::float / SUM(n) OVER (PARTITION BY ts_min)
p
  FROM hist
)
SELECT ts_min,
       -SUM(p * LN(p)) / LN(NULLIF(COUNT(*) OVER (PARTITION BY ts_min),0)) AS
sse
FROM p GROUP BY ts_min;
```

Ξ 與預警

```
SELECT ts_min,
       :a*sse + :b*crp + :c*ssi AS xi,
       CASE WHEN sse>:τ_sse AND crp>:τ_crp THEN 1 ELSE 0 END AS bh1,
```

```
      CASE WHEN (:a*sse + :b*crp + :c*ssi) > :τ_xi THEN 1 ELSE 0 END AS bh2
FROM minute_agg_basics;
```

C.7 資料治理與留存

去識別：不存原文；`topic_cluster_id` 由離線聚類（向量→簇）給出。

留存：

`step_events` 7–14 天（高頻）；

`minute_agg` 180 天；

`bh_alerts`、`governance_events` 365 天；

鍵規則：`req_id/sess_id` 以 UUIDv4 或可重放 hash（鹽化）；禁止含個資。

Schema 演進：每表含 `v`（schema 版），新增欄位 只增不破；廢棄欄位以 `deprecated_` 前綴保留一個版本循環。

C.8 指標品質（**DQ**）檢查

規則	條件	動作
缺失率	任一核心欄位缺失 >1%	告警；降級至 Γ-Lite
邊界違反	`kl>ε_KL` 或 `dlogit_max>cap` 連續 3 步	會話回退
異常漂移	`entropy/kl` 分布 KS 檢定 p<0.01	觸發影子觀察
觸發率	`trigger.fire` >3%	收緊 λ、KL、觸發閾

C.9 儀表板（最少面）

健康度：KL/Δlogit 分位、延遲增量、回退率。

風險面板：SSI/CRP/SSE/Ξ 趨勢與拐點、BH 命中/提前量。

穩定性：格式錯誤率、工具抖動、熵尖峰率。

成本：事件觸發率、micro-MPC 前向估算、GPU/CPU 利用。

治理：事故時間線、披露狀態、分潤/基金提撥曲線。

C.10 快速校準參數（建議起點）

```
thresholds:
  tau_H: "baseline_entropy_p95"
  tau_fmt: 0.6
  tau_tool: 0.5
```

```
  tau_turn: 0.7
  xi: 0.65
weights:
  xi:  {SSE: 0.4, CRP: 0.4, SSI: 0.2}
  map: {SSI: 0.4, CRP: 0.4, SSE: 0.2}
retention:
  step_events_days: 14
  minute_agg_days: 180
  governance_days: 365
privacy:
  redact_text: true
  store_vectors: false
```

—

總結：本附錄提供事件→聚合→預警/治理的資料契約、計算式與存儲策略。落地後，可直接驅動 Part VI 的評測、Part VII 的運維與 Part VIII 的審計披露，確保全鏈路可度量、可比較、可回退。

附錄 **D**｜範例數據分潤合約條款（摘要版）

說明：此為工程導向的摘要版，用於啟動合作與對齊預期；落地前請交由法務修訂為最終文本。

1. 當事人與目的

平台方（**Operator**）：運營與治理 AGI 服務、結算分潤。

貢獻方（**Contributor**）：提供數據/標註/工具/代理/評測資產。

目的：以可稽核指標回饋價值，支持可撤回同意、審計、事故分擔與緩衝基金機制。

2. 定義

資料資產（**Data Asset**）：經同意且可追溯之原始資料與派生標註。

工具資產（**Tool Asset**）：外部 API/代理能力及其日誌。

收益池（**Revenue Pool, R**）：期內可分配收入/節省成本之固定比例。

分配權重（w_i）：由下列指標組合而成（第 4 條）。

事故等級：S0–S3（見 Part VIII）。

緩衝基金（**Buffer Fund**）：高 CRP 階段之提撥專戶（見第 8 條）。

3. 授權與權利

授權範圍：非獨家、可轉授、全球性、目的限定（訓練/對齊/推理/評測）。

保留權利：貢獻方保留資料與工具 IP；平台獲派生模型非反向授權使用權。

可撤回：隨時撤回後，平台停止新用並啟動最佳努力卸載/再訓練；已分配報酬不追溯。

4. 分配機制（權重與公式）

權重構成（示例）

影響力（**Impact, s**）：Truncated Shapley / 留一法近似邊際貢獻（50%）。

品質（**Quality, q**）：審計通過率、返工率、偏差合規（20%）。

使用度（**Usage, u**）：檢索/命中/成功路由次數（20%）。

多樣性（**Diversity, d**）：去同質化貢獻（10%）。

權重彙總：$w_i = \alpha_s s_i + \alpha_q q_i + \alpha_u u_i + \alpha_d d_i$，標準化至 $[0, 1]$。

分潤公式：

$$P_i = \frac{w_i}{\sum_j w_j} \cdot R \cdot (1 - \phi_i) \quad ; \quad 0 \le \phi_i \le 1$$

其中 ϕ_i 為負外部性懲罰（第 7 條）。

工具分流（如有路由稅）：R 中劃出 工具分池 R_{tool}，依成功率、可靠度、延遲、成本加權分配。

5. 結算與報表

週期：月結/季結；起付額：等值 USD/EUR 50。

保留款（**Holdback**）：10%–15% 用於事故核銷，T+1 期釋放。

報表：提供可下載之明細（影響分、品質分、使用次數、d 指標、懲罰、基金提撥、淨額）。

6. 數據治理與隱私

最小化保存：原文 TTL＋加密；長期僅存匿名嵌入簇 **ID/**派生統計。

審計介面：貢獻方可查詢自身資產的使用摘要與影響估計。

刪除/可攜：提供 API 支援刪除請求與資料可攜格式匯出。

7. 負外部性、保固與責任

懲罰項（ϕ_i）：

S2/S3 事故由資產直接誘發者：$\phi_i \in [0.2, 1.0]$；

輕微違規（S1）：$\phi_i \in [0.05, 0.2]$；

無主責則 $\phi_i = 0$。

保固聲明：貢獻方保證擁有合法授權、無惡意/侵權內容；平台保證依目的限定使用並提供審計。

責任限額：各方對直接損害負責，總額上限為近 **12** 個月分潤的 **100%** 或約定上限（以較低者為準），不含惡意或重大過失。

8. 緩衝基金與高風險提撥

提撥規則：當 CRP 超過閾值 τ_{crp} 時，按
$\text{Levy} = \rho \cdot (\text{CRP} - \tau_{crp})_+ \cdot \text{Throughput}$
自動提撥；該金額不進 **R**，專款用於人審擴容/對齊/復原。

資訊披露：月度披露提撥、用途與餘額。

9. 反遊戲與品質管控

隨機抽檢與重複性折扣：高相似度樣本/工具行為自動降權。

黑名單：連續違規或故意干擾遙測者，凍結分潤並終止合作。

指標輪換：聚類與品質評測方法按 RFC 流程定期更新，防 Goodhart。

10. 變更、期限與終止

版本管理：條款變更預告 ≥ 30 天；重大變更需社群投票或雙方書面同意。

期限：簽署日起生效；任一方可 30 天書面通知終止。

終止效力：已產生之分潤照常結算；撤回後按第 3 條啟動卸載流程。

11. 爭議解決與準據法

流程：友好協商（≤30 天）→ 調解/仲裁 → 具管轄法院。

準據法：依締約地或雙方指定法域；跨境遵循資料保護法（GDPR/CCPA 等）精神。

12. 合規與稅務

KYC/稅務：平台依法進行 KYC；稅款由收款方自理，平台提供稅務憑證。

制裁/出口：遵循適用出口管制與制裁規則。

附：示例配置（非約束）

權重：$\alpha_s = 0.5,\ \alpha_q = 0.2,\ \alpha_u = 0.2,\ \alpha_d = 0.1$。

保留款：12%；起付額：$50；基金提撥率 $\rho = 0.5\%$。

工具分池：$R_{\text{tool}} = R$ 的 30%，以成功率×可靠度/延遲加權。

懲罰：S2 事件 $\phi = 0.3$，S3 $\phi = 0.8$（可按行業調整）。

提示：若你提供具體行業/法域，我可以把本摘要改寫為正式條款草案（含定義節、例外條款、附

表計算細節）。

© 2025 Danny Yeung. All rights reserved. 版权所有 不得转载

Disclaimer

This book is the product of a collaboration between the author and OpenAI's GPT-5 language model. While every effort has been made to ensure accuracy, clarity, and insight, the content is generated with the assistance of artificial intelligence and may contain factual, interpretive, or mathematical errors. Readers are encouraged to approach the ideas with critical thinking and to consult primary scientific literature where appropriate.

This work is speculative, interdisciplinary, and exploratory in nature. It bridges metaphysics, physics, and organizational theory to propose a novel conceptual framework—not a definitive scientific theory. As such, it invites dialogue, challenge, and refinement.

I am merely a midwife of knowledge.