展望以《皇極經濟》的「道」、「德」拓撲 配合 **P8D II** 框架探討湧現的語義吸引子是如何體現出運算功能和融合通道 - 階段成果匯總

第一，這個 Session 已經建立相當完整的條件性功能接口數學，但沒有證明真實 LLM 內存在可獨立辨認的 Semantic Attractor Object。 前者研究「甚麼條件下接口充分」，後者研究「這種內生功能個體是否自然存在」，兩者證據要求不同。

第二，合成實驗最有價值的結果，是揭露幾種不能混淆的現象：觀測 Loss 可以為零而 Port 仍不充分；精確行為商可以分裂或合併；Port 可以先取得充分性、後來才取得功能正確性；真正的吸引子也可以完全不參與指定功能。

第三，後續工作不需要重新發明 Causal Abstraction 或 Circuit Discovery。 Geiger 等人（2025）已建立系統性的因果抽象理論；InterpBench（2024）提供已知電路的半合成 Transformer；MIB（2025）則分別評估電路及因果變量定位。下一階段應以這些現有工具和基準為對照，驗證 SMFT 路線能否提供額外的形成機制解釋、可否證預測或工程效益。

Outstanding Problems and Research Handover

Attractor Fusion → Functional Operator → Natural Functional Individual

—— SMFT、**P8D**、成界之學與 **AI** 功能個體形成研究：數學成果、實驗證據、理論邊界及下一階段工作總帳

Research Closure and Handover — 12 October 2026

Abstract

本文件總結一系列由 Semantic Meme Field Theory（SMFT）、Attractor Fusion、Proto-Eight Dynamics（P8D）與成界之學延伸而來的研究，重點是複雜系統如何形成具有可辨認功能、有效接口、因果組織及遞歸可重用性的 Functional Individuals。

研究最初希望理解多個 Semantic Attractors 如何透過 Adaptive Connection、Memory、Gating 及 Collective Dynamics，形成新的功能性整體。隨着數學推演深入，研究逐漸轉向更精確的問題：一個具有大量內部自由度的系統，在甚麼條件下可以透過 Effective Port，被下一級當成可靠的 Functional Operator 使用？

此問題已產生一套以 Protocol-Relative Behavioral Equivalence、Joint Port Closure、Counterfactual Sufficiency、Approximate Error Propagation 及 Functional Contract 為核心的條件性數學框架。

進一步研究亦提出 Functional Port Qualification Dynamics，利用可解析模型及合成數值實驗，研究資料相關性、隱藏通道依賴、反事實訓練及有效狀態商如何影響功能接口的成熟。

然而，最後的研究審計揭露了一項根本性的證據缺口。

上述數學及合成實驗並未證明，真實 LLM 內部自然存在一個邊界清楚、具有持續身份，而且可以像 Programming Object 一樣辨認的 Semantic Attractor。

研究者可以構造可靠的 Functional Abstraction，但這不等於已發現一個內生的 Natural Functional Individual。

因此，本 Session 最後補寫三篇方法論研究，分別探討自然功能個體與研究者施加的抽象之區別、Transformer 中真正的 Attractor 定義，以及可以區分功能包裝與內部因果組織的對照實驗。

本文件將全部成果整合成一份可獨立閱讀的研究總帳，明確列出：

已建立的數學結果；

已執行的合成實驗；

既有研究文獻已經解決的部分；

受到反例限制的較強主張；

尚未解決的數學及 AI 工程問題；

以及下一階段最值得優先進行的研究。

本文的中心結論是：

A qualified functional interface can be mathematically defined and experimentally tested. Whether it corresponds to a naturally formed, causally persistent, attractor-mediated individual inside an LLM remains an open scientific question.

1. The Research Question and Its Evolution

1.1 Original Question — Attractor Fusion

研究最初的核心直覺是：

複雜系統內部可能存在多種相對穩定的結構。

當它們透過 Connection、Memory 及相互作用建立持續關係時，可能形成具有新功能的高層整體。

例如：

(1.1) Attractor A + Attractor B + Coupling → Candidate Composite Structure.

進一步希望：

(1.2) Composite Structure → Functional Operator.

再透過遞歸：

(1.3) Functional Operators → Higher-Level Functional Organization.

這與 SMFT 中的 Semantic Attractor、Collapse Geometry、Observer Projection 及成界之學的遞歸開顯思想具有概念上的聯繫。

但這條生成路線一開始存在幾個未經證明的箭頭。

首先，兩項吸引結構形成耦合，不一定產生新的吸引子。

其次，新的吸引子不一定產生正確功能。

第三，正確功能不一定具有對下游充分的接口。

第四，一項合格的 Functional Operator 不一定是自然形成的獨立個體。

因此，研究逐漸由宏觀生成敘述，轉向逐段建立數學判準。

1.2 First Transition — From Attractor to Functional Operator

研究發現：

真正需要判定的，不只是某項內部結構是否穩定，而是它能否被下一級可靠使用。

因此，提出 Effective Port 的概念。

對完整狀態 s，定義：

(1.4) p = Π(s).

研究問題變成：

下游是否可以只使用 p，而不需要重新取得完整 s？

這促使研究進入 Behavioral Equivalence、Functional Sufficiency、Joint Port Closure 及 Approximate Composition。

1.3 Second Transition — From Operator to Qualification Dynamics

即使可以驗證某個 Port 是否充分，仍然不知道：

它如何形成？

如果 Port 尚未充分，學習是否可以使它成熟？

如果研究者不知道正確 Port，能否自行發現？

這促成 Functional Port Qualification Dynamics。

其研究對象不再只是靜態接口，而是訓練中的功能、表示及因果作用如何變化。

1.4 Third Transition — From Qualified Port to Natural Individual

最後出現更根本的問題：

即使我們成功找到一項合格的 **Functional Port**，是否已經證明模型內部存在一個自然形成的功能個體？

答案是否定的。

Port 可以由研究者指定。

功能抽象可以相對於使用協議成立。

同一功能可以具有多種內部實現。

而真正的 Attractor 必須另有明確的狀態演化與吸引性證據。

這是本 Session 最重要的研究轉折。

2. The Source-Theory Background

2.1 Proto-Eight Dynamics

P8D 及相關工程手冊，以先天八卦的四組關係啟發工程化的功能分類。

其中較直接的工程對照包括：

乾坤：Gradient／Gate。

艮兌：Boundary／Buffer／Exchange。

震巽：Trigger／Guidance。

坎離：Memory／Focus。

這套研究關心增長、孕育、可用流量、匹配、留存及系統恢復等問題。

其價值在於提供可以轉化成工程量測的功能角色。

但應避免由這些角色直接推論：

所有 AI 或自組織系統，都必須具有同一套八元結構。

尤其是原始 P8D 的增長方程、後續 P8D II 的有型別功能關係，以及更高層的五功能與九宮生成猜想，都需要分別驗證。

2.2 Semantic Meme Field Theory

SMFT 提出 Semantic Field、Observer Projection、Collapse、Semantic Potential、Attractor Basin 及 Observer-Dependent Geometry。

其中《Semantic Meme Field Theory: Foundations, Projection, and Dynamics》Chapter 12 已討論 Attractor Basin Engineering、Potential、Control 及 Collapse Navigation。

這些內容提供了候選語義動力學語言。

但它們不是對一般 Transformer 內部自然吸引子的實測證明。

要建立這種對應，需要明確的神經狀態映射、更新規則及實驗驗證。

2.3 PORE and Protocol-First Research

PORE 及 The Gauge Grammar of Self-Organization 強調：

對一個複雜系統的有效研究，應先聲明觀察邊界、量測規則、操作窗口及允許干預。

這與後來的 Protocol-Relative Functional Equivalence 非常相容。

但兩者的概念一致性，並不自動構成數學等價或共同本體論證明。

2.4 Declaration, Filtration, Trace, and Ledger

《From One Declaration to One Self-Revising Fractal》將 Declaration 表示為：

(2.1) $D_k = (q_k, \varphi_k, P_k, \hat{O}_k, \mathrm{Gate}_k, \mathrm{TraceRule}_k, \mathrm{ResidualRule}_k)$.

並以：

(2.2) $D_{k+1} = U_adm(D_k, L_k, R_k)$.

描述受約束的修訂。

這提供了功能身份、歷史及治理的一項候選語法。

但 Declaration Revision Dynamics 與 Transformer Hidden-State Dynamics 是兩套不同系統。

即使兩者都可以研究固定點或吸引性，也不能無條件視為同一個 Attractor。

3. Evidence Status Ledger

本文件將研究成果分為六種證據級別。

Code	Status	Meaning
M	Mathematical Result	在明確假設下有證明，包含成熟數學的直接應用
S	Synthetic Result	已在指定解析或合成數值模型中得到結果
E	External Empirical Support	相關機制或方法有既有外部實驗文獻支持
H	Hypothesis	有明確猜想，但尚缺少相應驗證
O	Open Problem	仍欠定義、證明、識別性或必要實驗
X	Limited／Disconfirmed Claim	已有反例，或普遍性必須收窄

同一項研究問題可以同時具有不同級別。

例如：

Functional Port Closure 可以具有 M 級別的條件性定理。

在合成模型中可以具有 S 級別的驗證。

但其對真實 LLM Semantic Attractor 的解釋，仍可能只是 H／O。

不能由某一層的數學成熟，直接提升另一層的經驗證據級別。

4. Mathematical Results Established or Reorganized

M1 — Protocol-Relative Behavioral Equivalence

給定一個確定性狀態系統，以及固定、明確的有效操作協議，可以根據全部允許的未來輸出軌跡建立行為等價關係：

(4.1) $s_1 \sim_P s_2$.

其標準行為商為：

(4.2) $Q_P = S/\sim_P$.

在固定系統與操作規則下，這可以構成保留指定未來行為的狀態約化。

此項數學與 Automata Theory、Behavioral Equivalence、Bisimulation 及 State Abstraction 直接相關。

Status：**M**；主要為既有數學的組合及應用。

M2 — Exact Joint Port Closure

對聯合系統：

(4.3) $s' = F(s,b,u)$.

(4.4) $b' = G(s,b,u)$.

(4.5) $y = H(s,b,u)$.

令：

(4.6) $p = \Pi(s)$.

若希望存在只依賴 (p,b,u) 的精確聯合有效模型，則對任何具有相同 Port 的兩個有效內部狀態 s_1、s_2，都需要：

(4.7) $\Pi[F(s_1,b,u)] = \Pi[F(s_2,b,u)]$.

(4.8) $G(s_1,b,u) = G(s_2,b,u)$.

(4.9) $H(s_1,b,u) = H(s_2,b,u)$.

在已聲明的狀態、操作及封閉性條件下，這些條件構成相應的精確函數分解判準。

這是整個 Functional Operator 研究最重要的數學核心之一。

Status：**M**。

M3 — Function Correctness and Port Sufficiency Are Independent

一項 Port 可以充分保留錯誤的功能。

一個系統可以正確計算指定答案，卻沒有建立研究者希望使用的充分 Port。

因此：

(4.10) Port Sufficiency $\not\Rightarrow$ Functional Correctness.

(4.11) Functional Correctness $\not\Rightarrow$ Candidate Port Sufficiency.

這些反例限制了 Operator Formation 的定義。

Status：**M／X**。

M4 — Approximate Port Error and Composition

當 Port 只有近似充分性時，需要指定誤差上界、Lipschitz 條件、有效時域及外部使用規則。

典型形式為：

(4.12) $e_{n+1} \le Le_n + \varepsilon$.

在閉環系統中，若下游策略本身對狀態誤差敏感，則還需要把 Policy Sensitivity 納入分析。

因此，局部 Port 誤差很小，不一定保證長期組合誤差仍然很小。

Status：**M**；依賴明確的穩定性及有界性假設。

M5 — Finite-State Port Discovery

對完整已知的有限確定性系統，可以利用 Partition Refinement，自動找出符合指定功能轉移條件的最粗精確狀態分割。

演算法在有限步數內終止。

但它發現的是既有系統的功能抽象，不是自行創造新的功能。

Status：**M**；與成熟的 **Automata Minimization** 和 **Partition Refinement** 研究相關。

M6 — Observational Non-Identifiability

若兩套不同的因果系統，在可觀測資料分佈上完全一致，但對某些有效干預具有不同反應，則單靠該觀測分佈，不能普遍保證恢復正確的干預功能模型。

因此：

(4.13) Observational Fit ⇏ Causal Identification.

這是 Functional Port Discovery 的根本限制。

Status：**M**。

M7 — Correlation-Dependent Port Qualification

在雙通道模型：

(4.14) $y = wp + vh$.

目標為：

(4.15) $y^* = p$.

若：

(4.16) $\rho = E[ph]$.

則平方損失為：

(4.17) $J_\rho = (w - 1)^2 + v^2 + 2\rho(w - 1)v$.

其 Hessian 條件數，在 $|\rho| < 1$ 時為：

(4.18) $\kappa = (1 + |\rho|)/(1 - |\rho|)$.

因此高度相關的必要通道與隱藏通道，可能使其作用難以識別及優化。

但這是特定線性模型的結論，不能無條件套用於一般 Transformer。

Status：**M**。

M8 — Observational Residual versus Counterfactual Fiber Residual

在上述模型中，最佳觀測 Port-only Predictor 的均方殘差為：

(4.19) $R_{obs} = v^2(1 - \rho^2)$.

但若允許固定 p、獨立改變 h，則最小最壞絕對 Port 誤差為：

(4.20) $R_{cf} = |v|$.

所以，當 $|\rho|$ 趨近 1，觀測殘差可以趨近零，但反事實殘差未必降低。

Status：**M**。

M9 — Counterfactual Training Can Resolve a Particular Identifiability Failure

在完全相關資料 h = p 下，原本的觀測損失只有：

(4.21) $J_{obs} = (w + v - 1)^2$.

它具有多個零損失解。

若加入有效的 Fiber Consistency：

(4.22) $J_{total} = (w + v - 1)^2 + 4\lambda v^2$.

其中 $\lambda > 0$，則唯一最小點為：

(4.23) $(w^*, v^*) = (1, 0)$.

這說明在指定模型及有效干預條件下，反事實約束可以消除一類隱藏依賴。

但它預先假設候選 Port 已保存必要資訊。

Status：**M**；不是自主 **Port Discovery** 定理。

M10 — Developmental Quotient Is Not Monotonic

在四狀態模型中，目標功能改善，可以伴隨精確行為商的分裂或合併。

因此：

(4.24) Better Function $\not\Rightarrow$ More Quotient States.

以及：

(4.25) Better Function $\not\Rightarrow$ Fewer Quotient States.

兩者都不具有一般普遍性。

此外，商的區塊數相同，也不代表分割內容或功能身份相同。

Status：**M**／**X**。

M11 — Port Transport and Version Compatibility

對兩項 Port：

(4.26) $\Pi_1 : S \to Z_1$.

(4.27) $\Pi_2 : S \to Z_2$.

存在 A 使：

(4.28) $\Pi_2 = A \circ \Pi_1$.

當且僅當 Π_2 在 Π_1 的每個纖維上保持常值。

這可以用來研究：

Port 的可逆重新編碼；

資訊合併；

資訊細化；

以及不可比較的版本變化。

但資訊相容不等於 Runtime Functional Compatibility。

Status：**M**。

M12 — An Attractor Is Neither Necessary nor Sufficient for Arbitrary Correct Computation

前饋計算可以完成指定功能，而不需要研究者所聲稱的反覆吸引動力。

另一方面，一個穩定固定點可以與目標功能完全無關。

因此：

(4.29) Functional Operator ⇏ Specified Dynamical Attractor.

(4.30) Stable Attractor ⇏ Correct Functional Operator.

這兩種反例，限制了任何過強的 Attractor Universality Claim。

Status：**M／X**。

5. The Synthetic Experiment Ledger

S1 — Attractor Fusion XXV：Exact Port Sufficiency

此前的相位約化模型，使用：

(5.1) $q = \exp[i(\theta_A - \theta_B)]$.

並引入交互記憶 m。

在指定的相位差模型中，(q,m) 可以形成精確封閉的有效狀態，但單獨使用 m 通常不充分。

此結果依賴原模型具有共同相位對稱性，以及指定的下游交互方式。

同一研究亦加入宣告式 Gate、Admission、Revocation 及 Ledger。

但 Gate 的門檻是工程上預先設定，不是由系統自行發現。

Status：**S**。

S2 — Attractor Fusion XXVI：Heterogeneous Port and Attractor Maturation

研究包含相位振盪器、雙穩態標量、交互記憶及下游 Client。

在指定模型中，構造：

(5.2) $q = bz$.

並證明在某些狀態限制下，可以得到精確或近似的有效動力學。

在有限振幅模型中，Port Residual 具有：

(5.3) $R_q = (1 - |z|^2)(1 - b^2)q$.

當 z 向單位圓吸引流形靠近時，這項 Residual 可以衰減。

合成數值結果中，24 組初始條件的平均瞬時 $|R_q|$，由 t=0 時約 0.18109，下降至 t=4 時約 8.97×10^{-6}，以及 t=10 時約 3.51×10^{-11}。

但這個吸引流形是由模型方程明確給定。

這不是發現真實 LLM 的 Semantic Attractor。

Status：**S**。

S3 — Protocol-Relative Failure

在 XXVI 的模型中，原來有效的 Port，可以在擴大下游干預範圍後失效。

因此：

(5.4) Port Sufficient under P_1 ⇏ Port Sufficient under P_2.

特別是當 P_2 允許改變原來被 Port 省略的內部自由度之因果作用時。

這提供了 Protocol-Relative Sufficiency 的直接合成反例。

Status：**S**，並與 **M2** 的一般判準一致。

S4 — Attractor Fusion XXVII：Interpretation Audit

XXVII 的審計特別指出：

某些 Port Ranking 受到預先設定的表示成本影響。

某些對照的功能差異，不足以建立新 Operator 的必要性。

而精確 Port Closure 亦不等於新的吸引子已經出生。

這些限制應視為研究成果的一部分。

它們避免把漂亮的合成模擬，誇大為自然功能個體的發現。

Status：**S／X**。

S5 — Four-State Learning Experiment

最近的四狀態實驗使用：

(5.5) $p,h \in \{-1,+1\}$.

(5.6) $y = wp + vh$.

(5.7) $y^* = p$.

在完全相關的觀測資料 $h = p$ 上，模型第一次更新後便得到：

(5.8) w = v = 0.5.

因此觀測 Loss 為零。

但真正的反事實 Port Error 仍為 0.5。

這直接驗證了觀測擬合與 Port 充分性可以分離。

Status：**S**。

S6 — Quotient Split／Merge

對同一模型加入反事實訓練及稀疏化後，精確行為商類數出現：

(5.9) 1 → 3 → 4 → 2.

但應注意：

這是模型輸出等價類的結構變化。

其數值主要由解析可求解的權重更新決定。

它不是從未知神經網絡中發現的新相變，也不是 Attractor Bifurcation。

Status：**S**。

S7 — Functional Qualification and Composition

在同一實驗中：

觀測 Loss 最早達到零；

Port Residual 隨後達標；

精確 Port Closure 在稀疏權重歸零時成立；

單次功能資格更晚達標；

三級固定功能調用的最壞誤差在 k=19 才低於預設門檻。

反事實訓練組在沒有精確 Quotient Merge 的情況下，也能取得相同的三級組合資格。

因此：

(5.10) Exact Quotient Merge ≠ Approximate Functional Qualification.

但三級組合只是重複調用同一已知功能。

並未訓練出一個真正的新下游神經功能。

Status：**S**。

5.8 What These Synthetic Results Do Not Establish

上述所有合成結果均不能直接證明：

一般 Transformer 具有相同的 Port Formation Dynamics。

LLM 中所有功能都存在有限維度的充分 Port。

自然語義個體具有同樣的吸引方程。

Functional Operator Birth 必然伴隨 Quotient Split／Merge。

或者整套 SMFT 宇宙論已得到經驗支持。

這些都是需要新的證據才能成立的較強主張。

6. External Research and Academic Positioning

6.1 State Abstraction Is Established Mathematics

Automata Minimization、Partition Refinement、Behavioral Equivalence、Bisimulation 與相關控制理論，已經研究了如何合併保留必要未來行為的狀態。

因此，最粗功能狀態商及其有限狀態演算法，不宜作為全新數學發明來介紹。

6.2 Causal Abstraction Is Already a Mature Research Direction

Geiger 等人的研究，已建立高層因果模型與神經網絡低層計算之間的忠實抽象理論。

Activation Patching、Interchange Intervention、Circuit Analysis、Distributed Alignment 等工具，都已有明確的研究傳統。

因此，單純提出功能 Port 並使用干預驗證，不足以構成新的原創性主張。

6.3 Known-Circuit Benchmarks Already Exist

InterpBench 提供具有已知電路的半合成 Transformer。

MIB 則提供 Circuit Localization 與 Causal Variable Localization 等研究基準。

因此，本研究應直接利用或參照這些 Benchmark，而不是重新發明同一類基本工具。

6.4 Transformer-Related Attractor Mathematics Already Exists

Modern Hopfield Networks 已建立 Attention 與聯想記憶更新之間的數學關係。

Universal Transformers 及 Deep Equilibrium Models 則提供可研究反覆狀態更新與固定點的相關架構。

這說明 Attractor 與 Transformer 並非只有隱喻性聯繫。

但仍然不能由此直接證明一般 LLM 的每個語義或功能單元都是自然形成的 Attractor Object。

6.5 Candidate Incremental Contribution

本研究較有希望建立的增量價值，不是重新發明上述理論。

而是研究：

功能接口的因果資格如何隨訓練形成；

何種反事實資料有助於發現及修訂接口；

有效功能身份如何跨 Checkpoint 改變；

吸引動力是否對功能恢復及可靠性具有額外作用；

以及如何區分忠實功能抽象與具有內生因果組織的候選功能個體。

但這些方向目前仍需實際實驗，才能判定是否提供超出既有方法的預測或工程效益。

7. The Central Unresolved Gap

7.1 We Have Formal Ports, but Not Verified Natural LLM Objects

目前可以明確定義：

完整狀態；

候選 Port；

功能輸出；

下一步有效轉移；

及 Port Residual。

但對一般 LLM，我們尚未發現一個經完整驗證、可像 Programming Object 一樣界定其自然邊界的 Semantic Attractor。

因此，不能把合成模型中的 p、q、m 或其它人工定義的變量，直接當成已在真實 LLM 中被辨認的自然物件。

7.2 Faithful Abstraction versus Endogenous Individual

一項充分 Port 可以只是研究者選擇的有效描述。

一項真正的 Natural Functional Individual，則還需要較強的因果組織與持續性證據。

因此：

(7.1) Qualified Functional Port ⇏ Natural Functional Individual.

而且：

(7.2) Natural Functional Individual ⇏ Necessarily a Dynamical Attractor.

7.3 The Core Scientific Question

整個後續研究的中心問題應改為：

Can we find a functional organization inside a naturally trained AI model whose causal boundaries, operational sufficiency, and developmental persistence are supported by the model itself, rather than merely by an investigator-chosen representation?

中文：

能否在自然訓練的 **AI** 模型中，發現一套由模型自身因果組織支持的功能結構，使其邊界、接口充分性及形成歷史，不只是研究者任意選擇的表示？

這是一項比單純找到 Attractor 或 Circuit 更強的研究問題。

8. Outstanding Problems — Mathematical and Conceptual

O1 — Nontrivial Natural Functional Boundary

Priority：**Critical**

如何定義一項既不是 Identity Port、又不是研究者任意壓縮的功能邊界？

目前 Port Sufficiency 只能判定指定功能是否被保存。

但它不能單獨證明候選 Port 對應自然個體。

需要研究：

多個 Protocol 下的因果穩健性；

內部相互依賴；

外部可替代性；

及表示成本。

尚未建立 Natural Functional Individual 的公認充要定理。

Status：**O**。

O2 — Cross-Protocol Functional Identity

Priority：**High**

當 Protocol 由 P_1 擴展到 P_2，原來的 Port 可能失效。

但是否存在一組合理的 Protocol，使某項功能邊界在其中保持穩健？

如何排除任意強的干預，避免任何非平凡 Port 都被破壞？

如何量化跨協議的相容性，而不只是逐項比較 Accuracy？

Status：**O**。

O3 — Port Identifiability under Limited Interventions

Priority：**Critical**

在不能任意操作全部神經狀態的情況下，如何判定候選 Port 是否充分？

需要研究：

有效的 Interchange Interventions；

分佈支撐；

Counterfactual Coverage；

Off-Manifold 風險；

及未觀察到的 Hidden Bypass。

有限審計不能在沒有額外假設時證明全域 Port Sufficiency。

Status：**M for limitation**；**O for general solution**。

O4 — Automatic Port Discovery

Priority：**Critical**

能否在沒有人工指定 Carry、Arithmetic Register 或其它語義變量的情況下，自動找到非平凡的充分 Port？

有限狀態下有成熟精確演算法。

但高維神經網絡仍然涉及：

表示類別；

優化；

干預樣本；

成本約束；

及可識別性。

Status：**M for finite systems**；**O for unrestricted neural systems**。

O5 — Functional Birth versus Retrospective Discovery

Priority：**Critical**

最終 Checkpoint 中發現一項漂亮的功能電路，究竟表示：

該功能剛剛形成；

還是研究者現在才發現原本存在的結構？

需要透過訓練軌跡、Checkpoint 比較及訓練干預建立形成時間與因果貢獻。

Status：**O**。

O6 — Developmental Quotient Geometry

Priority：**High**

當模型訓練時：

哪些狀態應該被合併？

哪些狀態應該被分開？

如何在不同 Checkpoint 的 Activation 座標不一致時，追蹤相同功能身份？

不能只以 Cluster Count 或 Quotient Cardinality 作為 Operator Formation 指標。

Status：**M／S for simple models**；**O for real Transformers**。

O7 — Functional Compression and Minimality

Priority：**High**

一個低維度 Port 是否真的比較好？

若它需要昂貴的非線性讀取、複雜的 Adapter 或頻繁重訓，下游總成本可能反而更高。

因此，Port Minimality 應從純維度或資訊量，推向 Runtime Complexity、Reliability 及 Governance Cost。

Status：**O**。

O8 — Functional Contract under Self-Revision

Priority：**High**

若 Operator 的內部實現及 Port 不斷修訂，如何保持既有下游接口可靠？

甚麼情況需要重新資格認證？

如何防止以修改 Protocol 的方式掩蓋先前失敗？

這與 Declaration、Trace、Residual 及 Ledger 研究直接相關。

但仍需要可執行的 Runtime Governance Protocol。

Status：**H／O**。

9. Outstanding Problems — Attractor-Specific

O9 — What Is the Actual LLM Dynamical State?

Priority：**Critical**

研究者需要明確區分：

Transformer Layer State；

Recurrent Hidden State；

Autoregressive Context State；

Training Parameter State；

Semantic Projection State；

Declaration Revision State。

這些不天然共享相同的時間及更新算子。

因此，不能只因不同研究都使用 Attractor 一詞，就視為相同機制。

Status：**O for Semantic Attractor operationalization**。

O10 — Semantic-to-Neural Dynamical Correspondence

Priority：**Critical**

若提出：

(9.1) $\theta = \pi(z)$.

其中 z 是可测量神經狀態，θ 是語義狀態。

則需要建立兩者更新的相容關係。

例如：

(9.2) $\pi[T(z,u)] \approx S[\pi(z),u]$.

並量度相應 Residual。

如果找不到足夠可靠的 π 與 S，便不能把語義勢能或 Basin 模型，直接當成 LLM 內部的已驗證動力學。

Status：**O**。

O11 — Does Attraction Add Functional Value?

Priority：**Critical**

即使找到真正的吸引制度，仍需研究它是否改善：

Functional Correctness；

Perturbation Recovery；

Port Sufficiency；

Composition Reliability；

或 Training Efficiency。

若吸引結構對功能沒有額外因果作用，便不能將它稱為 Attractor-Mediated Operator 的形成機制。

Status：**H／O**。

O12 — Attractor Birth versus Attractor Maturation

Priority：**High**

既有吸引子逐漸增強穩定性，與新的吸引子透過分岔形成，是兩項不同現象。

Port Residual 下降，可以來自系統靠近原有吸引流形。

不能由此推論發生新的 Attractor Birth。

需要明確的參數掃描、局部穩定性及分岔證據。

Status：**O**。

O13 — Stochastic Semantic Basins

Priority：**Medium**

SMFT 的 Semantic Basin 模型可以包含隨機擾動。

此時需要區分：

Deterministic Attractor；

Metastable Basin；

Stationary Distribution；

及 Random Attractor。

若不能先建立正確的數學對象，便難以提出有意義的實驗主張。

Status：**O**。

10. Outstanding Problems — AI Engineering and Evidence

O14 — The Ground-Truth Natural Object Problem

Priority：**Critical**

對人工植入的模組，我們知道 Ground Truth。

但對自然訓練的 Transformer，研究者通常不知道真正的內部算法。

因此：

沒有植入指定模組，不等於模型沒有自行形成模組。

這使 Natural Functional Individual 的直接真假標註非常困難。

解決方法不能只是讓研究者事先寫好唯一正確答案。

需要使用多種因果測試、形成歷史及合理對照。

Status：**O**。

O15 — Decodable but Causally Unused Features

Priority：**High**

模型內部某個特徵可以完美預測 Carry。

但下游計算可能根本不使用該特徵。

因此必須區分：

Probe Decodability；

Causal Contribution；

及 Port Sufficiency。

否則會把相關性誤當成功能個體。

Status：**E for general methodological concern**；**O for proposed test performance**。

O16 — Genuine Attractor without Functional Contribution

Priority：**High**

一個神經系統可以具有真正的穩定吸引子。

但指定下游功能可能完全由另一條路徑完成。

因此需要吸引動力與功能貢獻的獨立測試。

這是下一階段必須保留的 Negative Control。

Status：**M／H**。

O17 — Natural Operator Formation across Seeds

Priority：**High**

若不同隨機種子都能學會相同功能，是否也會形成相容的內部因果結構？

如果沒有，究竟代表：

功能可以有多種自然實現；

還是研究者所假定的個體邊界並不穩健？

這需要允許不同的神經座標及電路實現。

不能只比較相同 Layer、相同 Neuron Index。

Status：**O**。

O18 — Recursive Functional Reuse

Priority：**High**

在合成模型中重複調用已知功能，不等於真實神經網絡已學會重用一項已形成的功能 Operator。

需要建立：

上游功能核心；

可驗證的 Effective Port；

全新下游任務；

及因果重用測試。

再與重新訓練及完整 Hidden State Baselines 比較。

Status：**S for synthetic compositions**；**O for genuine learned reuse**。

O19 — Autonomous Discovery and Self-Maintenance

Priority：**Long-Term**

一個系統能否在不預先指定高層功能分解的情況下：

發現候選 Port；

利用反例修訂它；

維持其有效資格；

並將它交給下一級使用？

更強地說，系統能否透過自身的內部機制，維持這種功能組織？

這接近 SMFT 所追求的自然個體及成界之學的自修訂問題。

但目前還欠缺通用的數學與實驗證據。

Status：**H／O**。

11. A Decisive Experimental Benchmark

11.1 Why a Controlled Benchmark Comes First

下一階段不宜直接分析大型商業 LLM，再試圖宣布已找到 Semantic Attractor。

這樣會遇到兩項主要困難：

我們不知道真正的 Ground Truth。

而且分析結果很難排除研究者事後選擇有利解釋的偏差。

因此，第一步應先建立能夠驗證發現工具能力的受控環境。

11.2 Six Controlled Model Classes

建議使用以下六類模型。

Model	Internal mechanism	Scientific role
M1	明確植入 Carry Module	模組發現正對照
M2	相同模組經可逆混合表示	座標不變性對照
M3	正常訓練、沒有預先植入指定模組的模型	未知內部結構的真正研究對象
M4	Carry 可被解碼，但候選特徵不被下游使用	因果誘餌負對照
M5	存在真正吸引動力，但不參與指定功能	Attractor 誤判負對照
M6	存在真正吸引動力，且下游使用它	Attractor-mediated 正對照

其中必須特別強調：

M3 不是自然個體不存在的負對照。

它只是沒有由研究者預先植入指定模組。

至於它在訓練中究竟形成甚麼結構，正是要研究的問題。

11.3 What the Benchmark Must Distinguish

研究者需要分別回答：

是否存在 Functional Port？

該 Port 是否通過反事實充分性測試？

其對應的內部電路是否具有真正因果作用？

是否存在真正的吸引動力？

吸引動力是否參與功能？

是否有足夠的形成歷史與穩健性證據，支持更強的內生個體主張？

不能只輸出一個二元標籤：

Natural Object = Yes／No。

11.4 Minimum Task

最初可以使用兩位二進制加法。

四個二元輸入：

(11.1) $a_0,a_1,b_0,b_1 \in \{0,1\}$.

只有：

(11.2) $2^4 = 16$.

種正常輸入。

完整輸入空間可以窮舉。

對全部有序 Base／Source 配對，最多可以建立：

(11.3) $16^2 = 256$.

種配對。

但配對的高層反事實結果，必須根據明確因果模型構造。

不能假設任意 Activation Swap 都是有效的 Carry Intervention。

11.5 Primary Experimental Endpoints

建議至少記錄：

Functional Accuracy。

Counterfactual Port Residual。

Interchange Intervention Accuracy。

Circuit／Causal Variable Localization。

Decoy False Positive Rate。

Cross-Representation Robustness。

Perturbation Recovery。

Functional Reuse。

以及 Total Compute／Intervention Cost。

全部結果都需要固定資料分割、模型版本及干預 Protocol。

12. What Would Count as a Scientific Breakthrough?

12.1 Level 1 — A Useful Tool

如果能建立一項方法，從小型神經網絡自動找到低成本、因果充分的 Functional Port，便已經具有工程價值。

尤其當它在新任務中可以可靠重用，而不需要重新展開完整神經狀態。

但這仍然主要是 AI Engineering／Causal Abstraction 成果。

12.2 Level 2 — A Better Formation Predictor

如果 Functional Port Residual 可以比普通 Task Accuracy 更早預測某項功能何時形成、何時能夠泛化或何時可以重用，便有可能取得新的機制研究價值。

但需要與現有 Grokking Progress Measures、Circuit Analysis 及其它表徵指標比較。

不能只展示一條漂亮的形成曲線。

12.3 Level 3 — A Causal Mechanism of Operator Formation

若透過訓練介入證明：

特定的 Connection Adaptation 或 Representation Reorganization，對 Port Qualification 具有可重現的因果貢獻，

而且此結果跨多個模型種子、任務及合理干預保持成立，便可支持較強的 Operator Formation Mechanism。

12.4 Level 4 — Attractor-Specific Functional Advantage

若能證明：

某項真正的吸引動力，不只是與功能同時出現，而是實際提高擾動恢復、功能正確性或下一級組合可靠性，

且這種效果在適當的資源及架構控制後仍然存在，便開始具有 Attractor-Mediated Operator 研究的獨立價值。

12.5 Level 5 — Endogenous Functional Individual

更高一級的成功，是找到一套功能結構，其因果邊界、內部組織及持續性，在多種合理描述及干預下都得到相容支持。

而且具有明確的形成歷史。

但即使取得這種結果，仍然需要謹慎決定：

它究竟是 Causal Module；

Natural Functional Individual；

還是更強的 Observer／Selfhood 候選。

這些概念目前尚不能無條件合併。

13. The Recommended Research Order

Phase 0 — Reproducible Mathematical Baseline

Priority：**Immediate**

將此前的合成研究整理成一個可重現的測試套件。

至少包括：

雙通道相關學習模型；

反事實 Fiber Residual；

有限狀態 Partition Refinement；

四狀態 Developmental Quotient；

以及 Attractor Fusion XXV–XXVII 的關鍵反例。

目標不是產生更多玩具模型。

而是將它們作為後續神經實驗工具的 Unit Tests。

Deliverable：**Validated Synthetic Benchmark Suite**。

Phase 1 — Known-Circuit Causal Discovery

Priority：**First Real AI Experiment**

使用已知電路的半合成 Transformer 或其它小型可控模型。

驗證分析工具能否：

找出真正的功能變量；

辨認其因果使用路徑；

拒絕 Decodable-but-Unused Decoy；

以及在可逆混合表示下保持正確性。

Deliverable：**Port Discovery and Causal Localization Report**。

Phase 2 — Naturally Trained Small Models

Priority：**Highest Scientific Value**

訓練多個沒有預先植入指定內部模組的小型模型。

保存完整 Checkpoint。

追蹤：

Functional Error；

Port Residual；

Internal Circuit Evidence；

及下游使用能力。

這一階段才真正開始研究 Function Formation，而不是只研究固定系統的事後抽象。

Deliverable：**Developmental Functional Individuation Traces**。

Phase 3 — Learned Recursive Reuse

Priority：**High**

對已形成的功能建立合格 Port。

再加入新的下游任務。

比較使用該 Port、使用完整 Hidden State，以及重新訓練全部系統的效果。

這樣才能測試：

Functional Operator 是否真正具有組合工程價值。

Deliverable：**Recursive Functional Reuse Benchmark**。

Phase 4 — Attractor-Specific Mechanisms

Priority：**After Functional Benchmarks**

使用 Hopfield-Type 或 Recurrent／Equilibrium Models，建立明確的吸引動力。

比較：

具有吸引動力的模型；

沒有相同吸引機制的功能等價對照；

以及具有吸引動力但不參與功能的負對照。

研究 Attractor 是否提供額外的可靠性或恢復性效益。

Deliverable：**Attractor-Mediated Function Causality Report**。

Phase 5 — SMFT／PORE Integration

Priority：**Conditional**

只有在前述實驗能夠穩定辨認 Functional Port 及其內部形成機制後，才嘗試進一步連接：

Semantic Potential；

Observer Projection；

Declaration；

Trace／Ledger；

及受約束的 Self-Revision。

每一項新概念都需要增加可測量的預測，而不只是增加描述性詞彙。

Deliverable：**SMFT-to-Neural Operational Correspondence Study**。

14. Stop Rules and Failure Conditions

14.1 Stop Rule A — No Incremental Predictive Value

如果 Port Qualification Metrics 無法提供超出 Accuracy、Loss 或既有 Circuit Metrics 的獨立預測價值，就不應繼續以新理論名稱重複相同分析。

應先重新檢查：

是否只是原有指標的重新編碼？

14.2 Stop Rule B — High False Positive Rate

如果方法頻繁把可解碼但未被使用的表示，或沒有功能貢獻的吸引結構，判成真正 Functional Individual，便不能提出較強的自然個體主張。

需要提高因果特異性。

14.3 Stop Rule C — Protocol Drift

如果為了讓某項 Port 通過資格，不斷修改有效輸入、干預或功能要求，便必須將其記錄為新 Contract。

不能把新 Contract 下的成功，直接當成舊 Contract 的驗證。

14.4 Stop Rule D — Trivial Identity Port

如果所找到的 Port 只是完整 Hidden State 的重新命名，且沒有相應的計算、表示或可靠性優勢，就不應宣稱取得非平凡的功能個體化。

14.5 Stop Rule E — Attractor without Functional Mechanism

如果找到穩定吸引制度，但相關功能不依賴它，就只能報告：

該系統存在相應的吸引動力。

不能報告：

該吸引子導致新的 Functional Operator 形成。

14.6 Stop Rule F — Failure of Ground-Truth Controls

如果一項發現工具不能可靠識別人工已知的正對照，也不能排除已知誘餌，就不應直接將它套用於大型未知模型，並作出自然個體存在的強主張。

15. Required Research Artifacts

為確保下一階段可以獨立重現，應建立以下工件。

15.1 Mathematical Specifications

保存：

完整狀態及更新方程；

Protocol；

候選 Port；

精確及近似 Sufficiency Criteria；

干預集合；

以及誤差界。

15.2 Synthetic Benchmarks

保留此前的 Attractor Fusion XXV–XXVII 程式及結果。

特別包括：

Port Closure 的代數驗證；

m-only Port 的反例；

Attractor Maturation Residual；

擴大 Protocol 後的失效；

以及 Cost-Sensitive Port Ranking 的審計。

15.3 Neural Model Artifacts

對每次真實 AI 實驗，保存：

Model Architecture；

Training Configuration；

Random Seeds；

Checkpoints；

完整資料分割；

以及必要的模型版本資訊。

15.4 Port Contracts

對每項候選 Port，保存：

來源 Layer／State；

表示映射；

目標功能；

有效輸入及上下文；

允許干預；

Port Error；

Qualification Threshold；

Downstream Interface；

及版本相容性。

15.5 Intervention Ledger

每項干預記錄：

Source State；

Target State；

修改內容；

預期高層因果結果；

實際結果；

是否可能 Off-Manifold；

以及其所屬 Contract Version。

15.6 Research Status Ledger

每項論文主張均標記：

M、S、E、H、O 或 X。

尤其不得把：

合成實驗；

條件性數學；

以及真實神經機制發現；

合併成同一個 Evidence Label。

16. Connections to the Larger SMFT and World-

Formation Program

16.1 What This Research Can Support

Functional Individuation 研究可以為 SMFT 提供：

明確的功能邊界判準；

候選 Observer-Relative Abstraction；

歷史功能身份的版本控制；

及部分可測量的自組織機制。

這些是具體的進展方向。

16.2 What It Cannot Yet Support

目前不能由這些結果證明：

SMFT 是普遍物理定律。

Semantic Attractor 已被證實為一般 LLM 的自然構成單元。

成界之學的遞歸生成過程是所有智能的必要結構。

P8D 八卦功能分類具有唯一普遍性。

或者從 Octonionic、$G_2/SO(4)$、Quaternion、$\mathbb{C}^2$ 到九宮等更高層結構的全部箭頭，都已獲得神經機制支持。

這些應保持為彼此相關、但仍需獨立證據的研究路線。

16.3 A Better Integration Principle

將不同理論放在同一篇研究中，應根據清楚的 Mapping Contract。

例如：

(16.1) Source State → Proposed Effective Variable.

(16.2) Source Dynamics → Proposed Effective Dynamics.

(16.3) Source Interventions → Effective Interventions.

(16.4) Residual → Error Bound.

(16.5) Functional Requirement → Measurable Prediction.

如果缺少其中的必要部分，便應將相應連接標記為：

Structural Analogy；

Candidate Mapping；

或 Open Hypothesis。

而不是宣稱已經證明統一機制。

17. The Most Important Research Hypotheses to Carry Forward

經過整個 Session 的修訂，建議只保留以下四項為下一階段的核心研究假說。

H1 — Learning-Driven Port Qualification

在某些神經學習系統中，訓練可能逐漸降低對非必要隱藏狀態的依賴，使候選 Functional Port 取得因果充分性。

Testing Requirement： 對比正常訓練、反事實訓練及合理 Baselines，量度未見過干預下的 Port Residual。

H2 — Developmental Functional Individuation

功能形成可能伴隨一項可追蹤的有效狀態結構變化，包括必要區分的建立及不必要依賴的消除。

Testing Requirement： 保存 Checkpoints，建立跨版本可比較的功能及因果紀錄。

H3 — Endogenous Functional Organization

自然訓練的神經網絡，可能形成在多種合理干預及觀察下仍可辨認的功能性因果組織。

Testing Requirement： 使用正負對照、跨表示測試、跨種子分析及訓練形成歷史，排除研究者施加接口所造成的假陽性。

H4 — Attractor-Mediated Functional Advantage

在具有明確動力學更新的神經系統中，某些吸引制度可能對功能接口的可靠性、恢復能力或組合能力提供額外優勢。

Testing Requirement： 真正的吸引動力、功能因果干預及資源匹配的非吸引式 Baselines。

這四項之中：

H1 最容易直接開始實驗。

H2 可以提供功能形成的發展性量測。

H3 最接近 Natural Functional Individual。

H4 最直接檢驗 SMFT 的 Attractor-Specific 研究主張。

它們可以互相支持，但不能相互代替。

18. Recommended Questions for the Next Research Session

下一個 Session 不必重新推演整個 Attractor Fusion I–XXVII。

建議由以下問題開始。

Question 1

在現有 Mechanistic Interpretability 工具中，哪些方法最適合在不知道高層變量的情況下，尋找

候選 Functional Port？

Question 2

如何利用 InterpBench 或 MIB 的已知電路環境，建立 Decodable-but-Unused 與 Attractive-but-Unused Negative Controls？

Question 3

在一個小型自然訓練 Transformer 中，能否追蹤 Functional Error 與 Counterfactual Port Error 的不同成熟時間？

Question 4

若發現了某個候選 Port，如何檢查它是研究者方便使用的抽象，還是對應真正可定位的內部因果組織？

Question 5

若模型具有循環或平衡結構，能否進一步驗證吸引性，以及吸引性是否對功能具有額外因果貢獻？

這五個問題已足以展開一輪相當完整的 AI 機制研究。

不需要在同一個實驗中，同時驗證 SMFT、PORE、P8D、八卦、五行、九宮及更高維的幾何主張。

19. A Compact Handover Contract

本 Session 的下一個研究階段，應遵守以下規格。

Research Objective

從自然訓練的神經模型中，尋找具有因果充分性、可重用性及形成歷史的候選 Functional Structures。

Initial Task

小型算術或其它具有完整反事實真值的可控任務。

Primary Baselines

Causal Abstraction、Circuit Localization、Distributed Alignment、InterpBench／MIB 類基準及普通 Functional Accuracy。

Primary Measurements

Functional Error、Counterfactual Port Residual、Causal Contribution、Cross-Representation Robustness、Reuse Reliability。

Primary Negative Controls

Decodable but Unused。

Attractive but Unused。

Trivial Identity Port。

Protocol-Shift Failure。

Functionally Equivalent but Structurally Different Implementations。

Evidence Boundary

不能從 Functional Port 的成功，直接宣稱已發現 Natural Semantic Attractor。

Success Criterion

至少提供一項超出既有 Baselines 的可重現預測、因果發現或工程可靠性改善。

Failure Criterion

若新框架不能提高因果特異性、預測能力或下游可重用性，便應收窄其主張，保留為概念整合或數學分析工具。

20. Final Assessment

本 Session 最初希望回答：

多個 Semantic Attractors 是否可以融合成新的功能個體？

經過數學推演、合成實驗及方法論審計，研究已經取得一項更精確的成果。

我們現在可以清楚區分：

一個結構是否具有吸引性；

一個系統是否能完成指定功能；

一項 Port 是否對下游充分；

一項接口是否具有可重用資格；

以及這項結構是否真正由系統內生形成。

這些是不同的數學與科學問題。

過去容易被描述為單一的 Attractor Fusion／Operator Birth，在嚴格研究下，實際包含多種可以彼此分離的事件。

功能正確性可以先於 Port 充分性。

Port 充分性也可以先於功能正確性。

有效狀態商可以分裂或合併。

吸引動力可以存在而沒有功能作用。

一個功能接口可以可靠使用，卻未必對應唯一的自然個體邊界。

因此，最大的成果並不是證明了一條普遍的生成定律。

而是：

我們已經知道，在提出這條生成定律之前，究竟有哪幾個不可省略的數學、因果及實驗問題需要先解決。

這使整個研究取得了更清楚的科學邊界。

它也令下一階段的工作不必再停留於概念層面的可能性推演。

最有價值的下一步，是進入真正的小型神經網絡實驗，測試 Functional Port Qualification Dynamics 是否能夠提供目前 Mechanistic Interpretability 研究尚未充分捕捉的形成過程。

若取得成功，SMFT 的部分 Attractor／Functional Individuation 思想便可能發展出具體的 AI 機制研究成果。

若沒有成功，也可以清楚辨認哪些部分只是有用的抽象、哪些是合成模型特有的性質，以及哪些更強的自然個體假說需要修訂。

這種結果同樣具有科學價值。

Final Research Thesis

The existence of a useful functional abstraction can be established mathematically under a declared protocol.

The emergence of a naturally organized functional individual requires evidence of endogenous causal structure, developmental persistence, and robustness beyond the investigator's chosen interface.

An attractor-mediated explanation requires still more: a specified dynamical system, reproducible attraction, and a demonstrated causal contribution of that attraction to function.

The outstanding task is to connect these three levels without confusing their evidence.

References and Source Map

A. Original Research Program

1. *Proto-Eight Dynamics (P8D): A Small, Testable Model of How Growth Actually Works【先天八卦動力學】.*
2. *Proto-Eight Meme Engineering: A Practical Systems Playbook Built on Incubation Trigram.*
3. *Proto-Eight Collapse Geometry: SMFT Applied to Growth, Memory, and Systems.*
4. *Semantic Meme Field Theory (SMFT): Foundations, Projection, and Dynamics (Rev1).*
5. *From One Assumption to One Operator.*
6. *From One Operator to One Filtration.*
7. *From One Filtration to One Declaration.*
8. *From One Declaration to One Self-Revising Fractal.*
9. *The Post-Ontological Reality Engine (PORE).*
10. *The Gauge Grammar of Self-Organization.*

11. *Attractor Fusion I–XXVII*, including the numerical and audit artifacts for XXV–XXVII.

B. Articles Developed in This Session

12. *From Semantic Attractors to Functional Operators: Input Sufficiency, Conditional Dynamics, Effective Ports, and Compositional Reliability*.

13. *The Emergence of Functional Operators in Transformers: Circuit Co-adaptation, Conditional Attractor Dynamics, and Reusable Effective Ports*.

14. *From Attractors to Recursive Functional Individuation: A Protocol-Relative Framework for Operator Formation and World-Building Systems*. Parts I–IV.

15. *Functional Port Qualification Dynamics: From Observational Fit to Counterfactual Sufficiency*. Parts I–IV.

16. *From Functional Abstraction to Natural Functional Individuals: Are AI Operators Discovered or Imposed?*

17. *What Is an Attractor in a Transformer? Mathematical Definitions, Execution Dynamics, Semantic Basins, and the Limits of Natural Functional Individuation*.

18. *Discovering versus Imposing AI Functional Objects: A Controlled Experimental Protocol for Causal Modules, Endogenous Boundaries, and Attractor-Mediated Functional Individuals*.

These session manuscripts are research drafts, not claims of peer-reviewed publication.

C. External Mathematical and AI Research

19. Paige, R., and Tarjan, R. E. (1987). *Three Partition Refinement Algorithms*. SIAM Journal on Computing, 16(6), 973–989.

20. Clarke, E., Grumberg, O., Jha, S., Lu, Y., and Veith, H. (2000). *Counterexample-Guided Abstraction Refinement*. Computer Aided Verification.

21. Geiger, A., et al. (2022). *Inducing Causal Structure for Interpretable Neural Networks*. ICML 2022.

22. Geiger, A., et al. (2025). *Causal Abstraction: A Theoretical Foundation for Mechanistic Interpretability*. JMLR 26(83), 1–64.

23. Gupta, R., Arcuschin, I., Kwa, T., and Garriga-Alonso, A. (2024). *InterpBench: Semi-Synthetic Transformers for Evaluating Mechanistic Interpretability Techniques*. NeurIPS 2024.

24. Mueller, A., et al. (2025). *MIB: A Mechanistic Interpretability Benchmark*. ICML 2025.

25. Ramsauer, H., et al. (2021). *Hopfield Networks Is All You Need*. ICLR 2021.

26. Dehghani, M., et al. (2019). *Universal Transformers*. ICLR 2019.

27. Bai, S., Kolter, J. Z., and Koltun, V. (2019). *Deep Equilibrium Models*. NeurIPS 2019.

28. Nanda, N., et al. (2023). *Progress Measures for Grokking via Mechanistic Interpretability*. ICLR 2023.

29. Montévil, M., and Mossio, M. (2015). *Biological Organisation as Closure of Constraints*.

Journal of Theoretical Biology, 372, 179–191.

End of Outstanding Problems and Research Handover

Research Status：Session Closure

本文件完成 Attractor Fusion → Functional Operator → Natural Functional Individual 研究路線的階段性整理。已建立的數學結果、合成實驗與外部文獻均已分別標記。真實 LLM 自然形成的 Semantic Attractor Object、其內生因果邊界與 Attractor-Mediated Functional Individuation，仍屬最主要的開放科學問題。本文件可作為下一個研究 Session 的起點，但不能替代尚未進行的神經網絡實驗。

我對下一個 Session 的首要建議是：不要再從宏觀 Semantic Attractor 出發，直接推演 Operator 的生成。先從可控的、真實訓練的神經網絡出發，研究能否發現非平凡且因果充分的功能接口，再循證據逐步向 Natural Functional Individual 和 Attractor 擴展。